

PCA des sauts — corpus unifié en blocs de 1 jour

36 médias, fenêtres ± 15 jours, seuils 4 et 6

Mêmes données et même chaîne que le rapport du corpus unifié en blocs de 3 jours, mais à la résolution du jour : les fréquences des 10 000 mots du top du *Monde* sont agrégées sur les 36 médias, un pic est un jour anormalement haut au regard d'une loi BNB ajustée en double fit (seuil de surprise 4 ou 6), et un NMS par mot garantit que deux pics gardés n'ont jamais de fenêtres qui se recouvrent. La détection donne 190 158 pics, dont 90 441 gardés par le NMS ; après exclusion de 850 pics trop près des bords de la grille, on obtient 89 591 fenêtres de ± 15 jours au seuil 4 et 32 939 au seuil 6. Chaque fenêtre est z-scorée sur elle-même, puis la PCA est faite séparément aux deux seuils.

Les quatre premières composantes




Figure 1. – Les quatre premières composantes aux deux seuils (parts de variance du seuil 6 en titre).

Les profils sont stables d'un seuil à l'autre. La composante 1 oppose l'activité après le pic à l'activité avant : à un bout les chocs exogènes (invasion de l'Ukraine, 7 octobre, confinement), à l'autre les événements anticipés. La composante 2 est une montée qui culmine la veille du pic puis s'éteint (Noël, fins de campagne). La composante 3 est une bascule sèche : creux la veille, maximum le lendemain — la forme des scrutins, où le vocabulaire de campagne s'arrête au vote et celui des résultats démarre le lendemain. La composante 4 porte des rebonds à ± 7 jours, le rythme hebdomadaire de parution (rubriques revenant le même jour de la semaine). Les composantes du seuil 6 sont orientées vers la queue lourde de leurs projections, et celles du seuil 4 alignées sur elles ; le fichier `composantes_unifie1j.npz` contient ces quatre profils et leurs parts de variance aux deux seuils.

Tranches de projection

Découpage repris de la figure 4 de l'article *Identifying new classes of financial price jumps with wavelets* (Aubrun, Morel, Benzaquen, Bouchaud — PNAS 2025) : pour chaque composante, les fenêtres sont triées par leur projection et découpées en trois tranches par les quantiles 10 % et 90 % — les deux tranches extrêmes isolent les fenêtres qui ressemblent le plus à la composante (d'un côté et de l'autre), la tranche centrale rassemble les 80 % restants — puis on trace le profil moyen de chaque tranche.




Figure 2. – Profils moyens des fenêtres par tranche de projection sur chacune des quatre premières composantes. Tranches délimitées par les quantiles 10 % et 90 % des projections.

Fenêtres archétypes

Pour chaque composante, les quatre fenêtres réelles (seuil 6) dont la projection sur elle est la plus forte, parmi les mots du vocabulaire « parlant » (vocab600). L'étiquette entre parenthèses situe le contexte du saut, posé à la main d'après les autres mots qui piquent le même jour.




Figure 3. – Fenêtres archétypes (seuil 6) : les quatre sauts réels les plus alignés sur chacune des quatre premières composantes.

Fichiers du dossier

composantes_unifie1j.npz — les quatre premières composantes (31 valeurs chacune, axe **blocs** de -15 à +15) et leurs parts de variance, aux deux seuils.

valeurs_propres_unifie1j.csv — les 31 valeurs propres de la matrice de covariance des fenêtres z-scorées (convention $S^2/(n-1)$ après centrage des colonnes), une colonne par seuil ; $n = 89\,591$ fenêtres au seuil 4, $32\,939$ au seuil 6.

projections_unifie1j.csv — une ligne par fenêtre (mot, date, surprise) avec ses coefficients sur les quatre premières composantes, aux deux seuils ; chaque seuil ayant sa propre PCA, les colonnes **c*_s6** sont vides quand la surprise est entre 4 et 6.

tops_mots_composantes_unifie1j.csv — pour chaque seuil, chaque composante et chaque côté (projections les plus positives et les plus négatives), les quinze fenêtres les mieux alignées, avec un drapeau **vocab600** pour filtrer les mots parlants.