

PCA des sauts — corpus unifié en blocs de 1 jour

36 médias, fenêtres ± 15 jours, seuils 4 et 6

La détection donne 190 158 pics, dont 90 441 gardés par le NMS ; après exclusion de 850 pics trop près des bords de la grille, on obtient 89 591 fenêtres de ± 15 jours au seuil 4 et 32 939 au seuil 6. Chaque fenêtre est z-scorée sur elle-même, puis la PCA est faite séparément aux deux seuils.

Les quatre premières composantes




Figure 1. – Les quatre premières composantes aux deux seuils (parts de variance du seuil 6 en titre).

Les profils sont stables d'un seuil à l'autre. La composante 1 oppose l'activité après le pic à l'activité avant : à un bout les chocs exogènes (invasion de l'Ukraine, 7 octobre, confinement), à l'autre les événements anticipés. La composante 2 est une montée qui culmine la veille du pic puis s'éteint (Noël, fins de campagne). La composante 3 est une bascule sèche : creux la veille, maximum le lendemain — la forme des scrutins, où le vocabulaire de campagne s'arrête au vote et celui des résultats démarre le lendemain. La composante 4 porte des rebonds à ± 7 jours, le rythme hebdomadaire de parution (rubriques revenant le même jour de la semaine).

Tranches de projection

Pour chaque composante, les fenêtres sont triées par leur projection et découpées en trois tranches par les quantiles 10 % et 90 % — les deux tranches extrêmes isolent les fenêtres qui ressemblent le plus à la composante (d'un côté et de l'autre), la tranche centrale rassemble les 80 % restants — puis on trace le profil moyen de chaque tranche.




Figure 2. – Profils moyens des fenêtres par tranche de projection sur chacune des quatre premières composantes. Tranches délimitées par les quantiles 10 % et 90 % des projections.

Fenêtres archétypes

Pour chaque composante, les quatre fenêtres réelles (seuil 6) dont la projection sur elle est la plus forte, parmi les mots du vocabulaire « parlant » (vocab600). L'étiquette entre parenthèses situe le contexte du saut, posé à la main d'après les autres mots qui piquent le même jour.




Figure 3. – Fenêtres archétypes (seuil 6) : les quatre sauts réels les plus alignés sur chacune des quatre premières composantes.

Fichiers du dossier

composantes_unifielj.npz — les quatre premières composantes (31 valeurs chacune, axe **blocs** de -15 à +15) et leurs parts de variance, aux deux seuils.

valeurs_propres_unifielj.csv — les 31 valeurs propres de la matrice de covariance des fenêtres z-scorées (convention $S^2/(n-1)$ après centrage des colonnes), une colonne par seuil ; $n = 89\,591$ fenêtres au seuil 4, 32 939 au seuil 6.

projections_unifielj.csv — une ligne par fenêtre (mot, date, surprise) avec ses coefficients sur les quatre premières composantes, aux deux seuils ; chaque seuil ayant sa propre PCA, les colonnes **c*_s6** sont vides quand la surprise est entre 4 et 6.

tops_mots_composantes_unifielj.csv — pour chaque seuil, chaque composante et chaque côté (projections les plus positives et les plus négatives), les quinze fenêtres les mieux alignées, avec un drapeau **vocab600** pour filtrer les mots parlants.

Annexe — archétypes des deux côtés

Les composantes ont été orientées vers la queue lourde de leurs projections, et la figure des archétypes ne montre que ce côté-là. Une composante décrit pourtant une opposition : son côté négatif — la forme inversée — a lui aussi ses fenêtres réelles. Pour chaque composante, les deux fenêtres (seuil 6, vocab600) dont la projection est la plus positive, puis les deux dont elle est la plus négative.




Figure 4. – Fenêtres archétypes des deux côtés (seuil 6) : pour chaque composante, les deux sauts réels de projection la plus positive (à gauche) et les deux de projection la plus négative (à droite).