

PCA des sauts — corpus unifié désaisonnalisé, blocs de 1 jour

36 médias, 10 000 mots, rythme hebdomadaire retiré par STL, fenêtres ± 15 jours, seuils 4 et 6

La série quotidienne de chaque mot est corrigée de son rythme hebdomadaire : une décomposition STL (période 7 jours, fenêtre saisonnière de 7 cycles, ajustement robuste) en extrait la composante saisonnière, qui lui est retirée. Les pics sont ceux de la détection d'origine, inchangés ; seules les fenêtres de ± 15 jours sont redécoupées dans les séries corrigées, soit 89 591 fenêtres au seuil 4 et 32 939 au seuil 6, comme avant. Chaque fenêtre est z-scorée sur elle-même, puis la PCA est faite séparément aux deux seuils.

Les quatre premières composantes




Figure 1. – Les quatre premières composantes aux deux seuils après correction, et la composante correspondante de la PCA d'origine (seuil 6). Parts de variance du seuil 6 en titre, part d'origine entre parenthèses.

Les quatre composantes sont celles de la PCA d'origine : même ordre, parts de variance égales à un point près, cosinus de 0,99, 0,98 et 0,95 pour les trois premières. La correction n'y change qu'une chose, les rebonds à ± 7 jours. La composante 3 garde sa bascule sèche (creux la veille, maximum le lendemain), débarrassée de ses ondulations hebdomadaires : c'est une forme d'événement, celle des scrutins, pas un artefact de parution. La composante 4 perd ses rebonds à ± 7 jours et devient l'opposition entre les épisodes étalés, où l'activité vit de part et d'autre d'un pic qui dépasse à peine le fond, et les pics brefs et massifs, la composante 4 de la grille de 3 jours. Le rythme hebdomadaire ne portait donc pas une composante à lui seul : il se superposait à celle-ci. La part des fenêtres à rythme hebdomadaire marqué passe de 9 % à 3 % (annexe B).

Tranches de projection

Pour chaque composante, les fenêtres sont triées par leur projection et découpées en trois tranches par les quantiles 10 % et 90 % — les deux tranches extrêmes isolent les fenêtres qui ressemblent le plus à la composante (d'un côté et de l'autre), la tranche centrale rassemble les 80 % restants — puis on trace le profil moyen de chaque tranche.




Figure 2. – Profils moyens des fenêtres par tranche de projection sur chacune des quatre premières composantes. Tranches délimitées par les quantiles 10 % et 90 % des projections.

Fenêtres archétypes

Pour chaque composante, les quatre fenêtres réelles (seuil 6) dont la projection sur elle est la plus forte, parmi les mots du vocabulaire « parlant » (vocab600) et avec au moins 20 occurrences au pic. L'étiquette entre parenthèses situe le contexte du saut, posé à la main d'après les autres mots qui piquent le même jour.




Figure 3. – Fenêtres archétypes (seuil 6) : les quatre sauts réels les plus alignés sur chacune des quatre premières composantes.

Fichiers du dossier

`composantes_desaison1j.npz` — les quatre premières composantes (31 valeurs chacune, axe `blocs` de -15 à +15) et leurs parts de variance, aux deux seuils.

`valeurs_propres_desaison1j.csv` — les 31 valeurs propres de la matrice de covariance des fenêtres z-scorées (convention $S^2/(n-1)$ après centrage des colonnes), une colonne par seuil ; $n = 89\,591$ fenêtres au seuil 4, 32 939 au seuil 6.

`projections_desaison1j.csv` — une ligne par fenêtre (mot, date, surprise) avec ses coefficients sur les quatre premières composantes, aux deux seuils ; chaque seuil ayant sa propre PCA, les colonnes `c*_s6` sont vides quand la surprise est entre 4 et 6.

`tops_mots_composantes_desaison1j.csv` — pour chaque seuil, chaque composante et chaque côté (projections les plus positives et les plus négatives), les quinze fenêtres les mieux alignées, avec un drapeau `parlant` (vocab600) pour filtrer les mots parlants.

`calibrage1j.csv` — les réglages de désaisonnalisation comparés (annexe B).

Annexe A — archétypes des deux côtés

Les composantes ont été orientées vers la queue lourde de leurs projections, et la figure des archétypes ne montre que ce côté-là. Une composante décrit pourtant une opposition : son côté négatif — la forme inversée — a lui aussi ses fenêtres réelles. Pour chaque composante, les deux fenêtres (seuil 6, vocab600, ≥ 20 occurrences au pic) dont la projection est la plus positive, puis les deux dont elle est la plus négative.




Figure 4. – Fenêtres archétypes des deux côtés (seuil 6) : pour chaque composante, les deux sauts réels de projection la plus positive (à gauche) et les deux de projection la plus négative (à droite).

Annexe B — réglages de désaisonnalisation comparés

Six réglages comparés au seuil 6, sur les mêmes fenêtres. Colonnes : part des fenêtres z-scorées dont l'autocorrélation à 7 jours dépasse 0,3 ; part de variance de la composante 4 et autocorrélation à 7 jours de son profil ; plus petit cosinus des composantes 1 à 3 avec leur homologue d'origine ; médiane de la part du pic absorbée par la composante saisonnière ; part des fenêtres dont le jour du pic n'est plus le maximum (2,7 % avant correction). Le profil hebdomadaire constant de `seasonal_decompose` ne retire presque rien : le rythme de parution change avec les rubriques et les médias au fil des années. La STL non robuste retire tout, mais en absorbant 18 % du pic et en déformant les trois premières composantes. La STL robuste à fenêtre par défaut est le compromis retenu ; les fenêtres plus longues (25, 53 cycles) déforment moins mais laissent la moitié du rythme.

	fenêtres à rythme 7 j	variance comp. 4	autocorr. 7 j comp. 4	cosinus min comp. 1-3	part du pic absorbée	pics déplacés
sans correction	9,1 %	6,2 %	-0,42	1,00	—	—
<code>seasonal_decompose</code> (profil constant)	7,1 %	6,1 %	-0,65	0,99	0,8 %	3,0 %
STL, fenêtre 7, non robuste	0,1 %	7,5 %	-0,80	0,67	18,2 %	6,8 %
STL, fenêtre 7, robuste (retenu)	3,2 %	6,4 %	-0,36	0,95	2,8 %	6,7 %
STL, fenêtre 25, robuste	5,3 %	6,0 %	-0,57	0,97	1,4 %	4,0 %
STL, fenêtre 53, robuste	6,0 %	6,0 %	-0,60	0,98	1,1 %	3,6 %