

PCA des sauts — corpus unifié désaisonnalisé, blocs de 3 jours

36 médias, 10 000 mots, rythme hebdomadaire retiré par STL, fenêtres ± 15 blocs, seuils 4 et 6

La série quotidienne de chaque mot est corrigée de son rythme hebdomadaire comme dans la version à 1 jour (STL, période 7 jours, fenêtre saisonnière de 7 cycles, ajustement robuste), puis agrégée en blocs de 3 jours sur la grille habituelle. Les pics sont ceux de la détection d'origine en blocs de 3 jours, inchangés ; seules les fenêtres de ± 15 blocs sont redécoupées dans les séries corrigées, soit 38 856 fenêtres au seuil 4 et 15 903 au seuil 6, comme avant. Chaque fenêtre est z-scoring sur elle-même, puis la PCA est faite séparément aux deux seuils.

Les quatre premières composantes




Figure 1. – Les quatre premières composantes aux deux seuils après correction, et la composante correspondante de la PCA d'origine (seuil 6). Parts de variance du seuil 6 en titre, part d'origine entre parenthèses.

Les composantes sont celles de la PCA d'origine en blocs de 3 jours, à un point de variance près et avec des cosinus de 0,93 à 1,00 : sur cette grille le rythme hebdomadaire est déjà brouillé (7 n'est pas un multiple de 3) et la correction ne change presque rien. La composante 1 oppose l'activité après le pic à l'activité avant, la composante 2 est la montée vers le pic qui retombe ensuite, la composante 3 creuse le bloc qui précède et rebondit juste après, la composante 4 oppose les épisodes étalés aux pics brefs et massifs. La part des fenêtres à rythme hebdomadaire marqué, déjà de 2 % avant correction, passe à 1 % (annexe B).

Tranches de projection

Pour chaque composante, les fenêtres sont triées par leur projection et découpées en trois tranches par les quantiles 10 % et 90 % — les deux tranches extrêmes isolent les fenêtres qui ressemblent le plus à la composante (d'un côté et de l'autre), la tranche centrale rassemble les 80 % restants — puis on trace le profil moyen de chaque tranche.




Figure 2. – Profils moyens des fenêtres par tranche de projection sur chacune des quatre premières composantes. Tranches délimitées par les quantiles 10 % et 90 % des projections.

Fenêtres archétypes

Pour chaque composante, les quatre fenêtres réelles (seuil 6) dont la projection sur elle est la plus forte, parmi les mots du vocabulaire « parlant » (vocab600) et avec au moins 20 occurrences au pic. L'étiquette entre parenthèses situe le contexte du saut, posé à la main d'après les autres mots qui piquent le même jour.




Figure 3. – Fenêtres archétypes (seuil 6) : les quatre sauts réels les plus alignés sur chacune des quatre premières composantes.

Fichiers du dossier

composantes_desaizon3j.npz — les quatre premières composantes (31 valeurs chacune, axe **blocs** de -15 à +15) et leurs parts de variance, aux deux seuils.

valeurs_propres_desaizon3j.csv — les 31 valeurs propres de la matrice de covariance des fenêtres z-scorées (convention $S^2/(n-1)$ après centrage des colonnes), une colonne par seuil ; $n = 38\,856$ fenêtres au seuil 4, 15 903 au seuil 6.

projections_desaizon3j.csv — une ligne par fenêtre (mot, date, surprise) avec ses coefficients sur les quatre premières composantes, aux deux seuils ; chaque seuil ayant sa propre PCA, les colonnes **c*_s6** sont vides quand la surprise est entre 4 et 6.

tops_mots_composantes_desaizon3j.csv — pour chaque seuil, chaque composante et chaque côté (projections les plus positives et les plus négatives), les quinze fenêtres les mieux alignées, avec un drapeau **parlant** (vocab600) pour filtrer les mots parlants.

calibrage3j.csv — les réglages de désaisonnalisation comparés (annexe B).

Annexe A — archétypes des deux côtés

Les composantes ont été orientées vers la queue lourde de leurs projections, et la figure des archétypes ne montre que ce côté-là. Une composante décrit pourtant une opposition : son côté négatif — la forme inversée — a lui aussi ses fenêtres réelles. Pour chaque composante, les deux fenêtres (seuil 6, vocab600, ≥ 20 occurrences au pic) dont la projection est la plus positive, puis les deux dont elle est la plus négative.




Figure 4. — Fenêtres archétypes des deux côtés (seuil 6) : pour chaque composante, les deux sauts réels de projection la plus positive (à gauche) et les deux de projection la plus négative (à droite).

Annexe B — réglages de désaisonnalisation comparés

Quatre réglages comparés au seuil 6, sur les mêmes fenêtres ; mêmes colonnes que dans la version à 1 jour, la part des fenêtres dont le pic n'est plus le maximum valant 1,2 % avant correction. La correction est calculée au jour puis agrégée en blocs ; sur cette grille la fenêtre de 25 cycles retire autant de rythme en déformant moins, mais le réglage de la version à 1 jour est conservé pour n'avoir qu'une seule chaîne.

	fenêtres à rythme 7 j	variance comp. 4	autocorr. 7 j comp. 4	cosinus min comp. 1-3	part du pic absorbée	pics déplacés
sans correction	2,2 %	7,0 %	-0,04	1,00	—	—
seasonal_decompose (profil constant)	1,6 %	6,8 %	-0,12	1,00	0,6 %	1,8 %
STL, fenêtre 25, robuste	1,2 %	6,7 %	-0,18	1,00	1,0 %	2,8 %
STL, fenêtre 7, robuste (retenu)	1,2 %	6,3 %	-0,26	0,93	2,1 %	5,9 %