

Résultats Kernel PCA

Mediapart, Les Échos, Le Figaro



MEDIAPART



Les Échos

LE FIGARO

Configurations étudiées

Les trois journaux partagent la même grille à 3 jours (blocs de 3 jours), la même largeur de fenêtre (± 10 blocs, soit $D = 21$) et le même seuil de surprise (5). Seul γ diffère d'un média à l'autre : il est calé sur l'échelle réelle des distances : $\gamma_{\text{méd}} = 1/(2 \cdot \text{médiane}(\|z_i - z_j\|^2))$, et la médiane est estimée sur 4 millions de paires de fenêtres tirées au hasard.

	Mediapart	Les Échos	Le Figaro
Fenêtres	4 665	8 188	9 676
médiane(d^2)	6,15	10,64	14,07
$\gamma_{\text{méd}}$	0,0813	0,0470	0,0355

Pour chaque (média, γ), le spectre est calculé **en entier** (N valeurs) et on calcule les 50 premiers vecteurs propres.

Comparaison avec la PCA linéaire

Trois γ retenus pour les trois journaux :

- $0,1 \cdot \gamma_{\text{méd}}$ — le plus proche du linéaire ;
- $\gamma_{\text{méd}}$ — le réglage « optimal » mesuré sur les données ;
- $30 \cdot \gamma_{\text{méd}}$ — le régime dégénéré.

	linéaire	$0,1 \cdot \gamma_{\text{méd}}$	$\gamma_{\text{méd}}$	$30 \cdot \gamma_{\text{méd}}$
Mediapart — 4 665 fenêtres, $\gamma_{\text{méd}} = 0,0813$				
comp1 (%)	11,13	11,11	13,49	6,24
K50	8	8	12	1 130
K90	17	19	173	3 042
Les Échos — 8 188 fenêtres, $\gamma_{\text{méd}} = 0,0470$				
comp1 (%)	15,89	15,51	13,46	2,90
K50	6	7	10	2 641
K90	17	18	131	6 078
Le Figaro — 9 676 fenêtres, $\gamma_{\text{méd}} = 0,0355$				
comp1 (%)	16,20	15,76	12,87	2,11
K50	6	6	9	3 264
K90	17	18	109	7 389

Figure 1. — Sur les 9 comparaisons (3 journaux $\times$ 3 γ), Mediapart est seul à voir comp1 kernel dépasser comp1 linéaire (13,49 % contre 11,13 % à $\gamma_{\text{méd}}$). Les Échos et Le Figaro reproduisent le schéma habituel.

Lecture

Le RBF ne concentre la variance que si les fenêtres vivent sur une surface courbe. Ici la seule variation entre fenêtres est une amplitude et une largeur autour de la même forme de saut — un continuum, pas une courbure — donc le noyau n'a rien à déplier. En projetant dans un espace de dimension infinie, il répartit le même budget de variance sur beaucoup plus de directions sans rien y gagner. Le dépassement sur Mediapart, le corpus le plus petit et le plus bruyé, reste à confirmer avant d'y voir un signal plutôt qu'un effet d'échantillon.