

Résultats Kernel PCA

Mediapart, Les Échos, Le Figaro



MEDIAPART



Les Échos

LE FIGARO

Configurations étudiées

Les trois journaux partagent la même grille hebdomadaire (blocs de 7 jours), la même largeur de fenêtre (± 10 blocs, soit $D = 21$) et le même seuil de surprise (4). Seul γ diffère d'un média à l'autre : il est calé sur l'échelle réelle des distances : $\gamma_{\text{méd}} = 1/(2 \cdot \text{médiane}(\|z_i - z_j\|^2))$, et la médiane est estimée sur 4 millions de paires de fenêtres tirées au hasard.

	Mediapart	Les Échos	Le Figaro
Fenêtres	5 483	8 633	11 311
médiane(d^2)	9,99	14,43	16,75
$\gamma_{\text{méd}}$	0,0501	0,0347	0,0299

Pour chaque (média, γ), le spectre est calculé **en entier** (N valeurs) et on calcule les 50 premiers vecteurs propres.

Comparaison avec la PCA linéaire

Trois γ retenus pour les trois journaux :

- $0, 1 \cdot \gamma_{\text{méd}}$ — le plus proche du linéaire ;
- $\gamma_{\text{méd}}$ — le réglage « optimal » mesuré sur les données ;
- $30 \cdot \gamma_{\text{méd}}$ — le régime dégénéré.

	linéaire	$0,1 \cdot \gamma_{\text{méd}}$	$\gamma_{\text{méd}}$	$30 \cdot \gamma_{\text{méd}}$
Mediapart — 5 483 fenêtres, $\gamma_{\text{méd}} = 0,0501$				
comp1 (%)	12,81	12,46	11,04	3,25
K50	8	8	11	1 764
K90	17	18	136	4 050
Les Échos — 8 633 fenêtres, $\gamma_{\text{méd}} = 0,0346$				
comp1 (%)	14,76	14,36	11,59	1,25
K50	6	7	10	3 284
K90	17	18	116	6 912
Le Figaro — 11 311 fenêtres, $\gamma_{\text{méd}} = 0,0299$				
comp1 (%)	14,12	13,69	10,73	1,01
K50	6	6	9	4 139
K90	17	18	114	8 936

Figure 1. — Sur les 9 comparaisons (3 journaux $\times$ 3 γ), comp1 kernel ne dépasse jamais comp1 linéaire. K90 explose d'un facteur 200 à 500 dès le régime dégénéré.

Lecture

Le RBF ne concentre la variance que si les fenêtres vivent sur une surface courbe. Ici la seule variation entre fenêtres est une amplitude et une largeur autour de la même forme de saut — un continuum, pas une courbure — donc le noyau n'a rien à déplier. En projetant dans un espace de dimension infinie, il répartit le même budget de variance sur beaucoup plus de directions sans rien y gagner.