

Kernel PCA des fenêtres de sauts

Le Monde et Les Échos — le noyau RBF ne concentre pas mieux la variance

Le Monde

 Les Échos

La question

La PCA linéaire des fenêtres de sauts laisse la variance très étalée : sur la configuration de référence (fenêtres ± 15 jours, seuil de surprise 4), les six premières composantes n'expliquent que 33,0 % de la variance au Monde et 34,3 % aux Échos, là où un nuage sans aucune structure en donnerait 20 %. La question posée : une **kernel PCA** — qui projette d'abord les fenêtres dans un espace plus riche, où des structures courbes deviennent des directions droites — resserrerait-elle ce spectre ?

Réponse courte : **non**. Le noyau RBF étale la variance au lieu de la concentrer, et l'écart se creuse à mesure que le noyau devient plus non linéaire. Le détour par un premier résultat trompeur, corrigé plus bas, vaut d'être raconté : il tient à une erreur de dénominateur facile à commettre.

Le protocole

Même chaîne que les autres configurations de la campagne — pics filtrés au seuil de surprise, NMS de portée $2d+1$, découpe des fenêtres, z-score le long de chaque fenêtre — puis, sur la **même matrice** de fenêtres z-scorées, deux décompositions comparées : la PCA linéaire habituelle et une kernel PCA à noyau gaussien (RBF), dont on balaie le paramètre de largeur γ sur deux ordres de grandeur.

Une contrainte de calcul impose un échantillonnage : la kernel PCA repose sur la matrice de Gram, de taille $N \times N$, qui compare chaque fenêtre à toutes les autres. Sur les 123 310 fenêtres du Monde, cette matrice pèserait environ 120 Go. Le test porte donc sur un **échantillon aléatoire de 8 000 fenêtres**, le même pour les deux méthodes afin que la comparaison reste honnête.

S'ajoute un **témoin** : 8 000 fenêtres de bruit blanc, z-scorées comme les vraies, sans aucune structure temporelle. Toute « concentration » que la méthode y trouverait ne mesurerait rien de réel.

Le piège du dénominateur

Le premier passage concluait à un gain net : la composante 1 passait de 9,3 % à 13,8 % au Monde, de 10,5 % à 17,3 % aux Échos, et le gain grandissait avec γ jusqu'à plus de 40 %. Ce résultat était **faux**.

En kernel PCA, on ne demande qu'un nombre fixé de composantes — ici 30, le rang d'une fenêtre z-scorée de dimension 31. La bibliothèque ne renvoie alors que ces 30 valeurs propres. Les diviser par leur propre somme donne « la part de la composante 1 **parmi les 30 retenues** », et non sa part de la variance totale : dans l'espace induit par le noyau, le rang ne s'arrête pas à 30, il monte jusqu'à N . Le bon dénominateur est la trace de la matrice de Gram centrée, qui vaut ici $\text{trace}(K) - \text{somme}(K)/N$.

L'écart n'est pas anecdotique. Au Monde, à $\gamma = 1/D$, les 30 composantes retenues ne pèsent que 67 % de la variance totale ; à $\gamma = 1$, plus que 4,6 %. Diviser par leur somme revient à ignorer les 95 % de variance partis dans les rangs supérieurs — exactement la variance que la question cherchait à mesurer.

Le même calcul lu de deux façons : diviser par la somme des seules composantes retenues
fabrique un gain qui disparaît dès qu'on rapporte à la variance totale




Figure 1. – À gauche, la lecture fautive : la variance cumulée des six premières composantes semble grimper avec γ et dépasser largement la PCA linéaire (pointillés). À droite, le même calcul rapporté à la variance totale : la courbe descend, et le noyau ne fait jamais mieux que le linéaire. Le témoin de bruit blanc (gris) tranche : à gauche il reste plat autour de 21 % et tend vers 20 %, soit exactement $6/30$ — la valeur qu'on obtient quand les 30 valeurs propres retenues sont égales et que le rapport ne mesure donc plus rien. À droite, le même témoin s'effondre vers 0 comme il se doit.

Le résultat corrigé

Avec le bon dénominateur, la kernel PCA ne bat la PCA linéaire sur aucun des deux journaux.

	Le Monde	Les Échos
Composante 1 — linéaire	9,3 %	10,5 %
Composante 1 — kernel ($\gamma=1/D$)	9,3 %	11,8 %
cum6 — linéaire	33,0 %	34,3 %
cum6 — kernel ($\gamma=1/D$)	24,9 %	27,2 %
cum6 — kernel ($\gamma=0,1$)	16,3 %	20,2 %
cum6 — kernel ($\gamma=1$)	2,5 %	5,6 %

La composante 1 est au mieux marginalement meilleure — identique au Monde, +1,3 point aux Échos — mais dès la deuxième composante le noyau décroche, et la variance cumulée est systématiquement inférieure. Plus γ grandit, plus l'écart se creuse.

Variance expliquée par composante : la kernel PCA ne concentre pas mieux
fenêtres ± 15 jours seuil de surprise 4 échantillon de 8 000 fenêtres




Figure 2. – Les deux spectres superposés à $\gamma = 1/D$. Passé le premier rang, la courbe kernel (bleu) reste sous la courbe linéaire sur toute la longueur du spectre : la variance est répartie sur davantage de directions, pas moins.

Pourquoi c'était prévisible

Le noyau RBF projette implicitement les données dans un espace de dimension infinie, où les points s'éloignent les uns des autres. La variance s'y répartit donc sur beaucoup plus de directions qu'en dimension 31 — c'est l'inverse d'une concentration. Une kernel PCA ne resserre le spectre que si les données vivent réellement sur une surface courbe de basse dimension : un nuage enroulé en spirale, deux groupes séparés par une frontière incurvée. Le noyau « déplie » alors cette surface.

Rien de tel ici. Le nuage des fenêtres reste le même continuum d'un plan à l'autre : une masse dense d'un côté, une traîne qui s'étire vers les sauts les plus marqués, sans groupe distinct ni structure enroulée que le noyau révélerait.

Le nuage des fenêtres dans le plan des deux premières composantes :
même continuum, aucun groupe que le noyau ferait apparaître




Figure 3. — Le nuage des 8 000 fenêtres dans le plan des deux premières composantes, linéaire à gauche, kernel à droite. Les échelles diffèrent — les projections kernel ne sont pas dans les unités des fenêtres — mais la géométrie est la même : un continuum, pas des groupes.

Ce que ça coûterait, même en cas de gain

Un point mérite d'être noté indépendamment du résultat : la kernel PCA n'aurait pas été gratuite à adopter. Ses composantes vivent dans l'espace induit par le noyau, pas dans celui des 31 jours de la fenêtre. Elles ne se tracent donc pas comme des **profils temporels**, et trois des cinq figures qui font l'interprétation de la campagne — profils des composantes, fenêtres archétypes, reconstruction progressive d'une fenêtre réelle — n'ont pas d'équivalent direct. Il aurait fallu un gain franc pour justifier de perdre l'interprétabilité ; il n'y a pas de gain du tout.

Réserves

- **Échantillon.** Le test porte sur 8 000 fenêtres tirées au hasard, contre 123 310 (Monde) et 48 336 (Échos) pour la PCA linéaire de la campagne. Les chiffres linéaires du tableau sont recalculés sur ce même échantillon, donc comparables ; ils diffèrent de quelques dixièmes de ceux du rapport principal.

- **Une seule famille de noyaux.** Seul le RBF a été balayé. Un noyau polynomial de degré 2 ou 3, qui n'envoie pas en dimension infinie, se comporterait différemment — mais rien dans la forme du nuage ne le rend prometteur.
- **Le z-score reste en amont.** La normalisation par fenêtre efface déjà l'échelle et une partie de la non-linéarité ; c'est un choix acté de la chaîne, pas une variable de ce test.

Conclusion

Le spectre étalé de la PCA des fenêtres n'est pas un artefact de linéarité : il reflète une vraie diversité de formes de sauts. Passer à un noyau ne le resserre pas, l'étale davantage, et coûterait l'interprétabilité des composantes. La PCA linéaire reste le bon outil pour cette chaîne.

Figures produites par `campagne_pca/figures_kernel.py`. Logos officiels via Wikimedia Commons. Méthode complète de la chaîne : `campagne_pca/rapport.pdf`.