

Kernel PCA : méthode et rôle de γ

La méthode

En entrée, la matrice Z de la campagne : n fenêtres de sauts z -scorées, $D = 21$ blocs chacune. La PCA linéaire diagonalise sa covariance ($D \times D$). La kernel PCA diagonalise à la place la matrice de Gram

$$K_{ij} = \exp\left(-\gamma \|z_i - z_j\|^2\right),$$

doublement centrée, de taille $n \times n$: les fenêtres sont comparées dans un espace de dimension infinie où des structures courbes deviendraient des directions droites, sans jamais calculer cet espace.

Deux points à garder en tête. La part de variance se rapporte à la trace de la Gram centrée, pas à la somme des valeurs propres calculées — le rang n'y est plus $D - 1$ mais n . Et le coût est en n^2 : 120 Go sur la grille journalière, d'où l'échantillon de 8 000 fenêtres du premier test ; 0,2 à 6 Go sur les grilles hebdomadaire et à 3 jours, ce qui donne toutes les fenêtres et le spectre entier.

Le paramètre γ

γ fixe à partir de quelle distance deux fenêtres cessent de se ressembler. Petit, $\exp(-\gamma d^2) \approx 1 - \gamma d^2$: on retombe sur la PCA linéaire. Grand, K tend vers l'identité, chaque fenêtre ne ressemble plus qu'à elle-même et le spectre s'aplatit — K90 passe de 17 composantes à plusieurs milliers.

Il n'a donc de sens qu'en regard des distances réelles, d'où le calage $\gamma_{\text{méd}} = 1/(2 \cdot \text{médiane}(\|z_i - z_j\|^2))$, médiane estimée sur 4 millions de paires tirées au hasard. Elle vaut 6 à 17 selon le média, contre $2D = 42$ pour des fenêtres décorréliées : elles se ressemblent beaucoup plus que ça. La grille balaie $\gamma_{\text{méd}} \times [0, 1 \dots 30]$, lue sur comp1, cum6 et K50/K90.

	linéaire	0,1 · $\gamma_{\text{méd}}$	$\gamma_{\text{méd}}$	30 · $\gamma_{\text{méd}}$
Mediapart — 5 483 fenêtres, $\gamma_{\text{méd}} = 0,0501$				
comp1 (%)	12,81	12,46	11,04	3,25
K50	8	8	11	1 764
K90	17	18	136	4 050
Les Échos — 8 633 fenêtres, $\gamma_{\text{méd}} = 0,0346$				
comp1 (%)	14,76	14,36	11,59	1,25
K50	6	7	10	3 284
K90	17	18	116	6 912
Le Figaro — 11 311 fenêtres, $\gamma_{\text{méd}} = 0,0299$				
comp1 (%)	14,12	13,69	10,73	1,01
K50	6	6	9	4 139
K90	17	18	114	8 936

Figure 1. — Grille hebdomadaire, trois γ par journal. Le noyau ne concentre jamais la variance mieux que la PCA linéaire : la forme des sauts varie en amplitude et en largeur, un continuum sans courbure à déplier.