

PCA des sauts — corpus unifié, vocabulaire étendu, blocs de 1 jour

36 médias, 11 780 mots, fenêtres ± 15 jours, seuils 4 et 6

Le vocabulaire est **étendu** : aux 10 000 mots du top du *Monde* (classés par jours de présence sur toute l'archive) s'ajoutent 1 780 mots du top par occurrences sur 2000-2025, absents du premier classement parce que récents (« ukraine », « macron », « covid », « confinement », « hamas », « gilets »...), soit 11 780 mots. Les séries ont été extraites sur les bases de l'ENS : mêmes 36 médias, mais *Le Figaro*, *Les Échos* et *Le Monde* y sont plus complets que dans le corpus unifié d'origine (*Le Figaro* et *Les Échos* jusqu'en août 2026 au lieu de mars et octobre 2024, *Le Monde* jusqu'en août 2026 au lieu de décembre 2025), soit 2,6 % de tokens en plus. La détection donne 228 272 pics, dont 109 476 gardés par le NMS ; après exclusion de 1 060 pics trop près des bords de la grille, on obtient 108 416 fenêtres de ± 15 jours au seuil 4 et 40 462 au seuil 6 (19 103 et 7 285 portées par les mots ajoutés). Chaque fenêtre est z-scorée sur elle-même, puis la PCA est faite séparément aux deux seuils.

Les quatre premières composantes




Figure 1. – Les quatre premières composantes aux deux seuils (parts de variance du seuil 6 en titre).

Les composantes sont celles de la PCA du corpus unifié à vocabulaire d'origine : cosinus de 0,98 à 1,00 avec les composantes correspondantes, parts de variance identiques au dixième près. Les profils sont stables d'un seuil à l'autre. La composante 1 oppose l'activité après le pic à l'activité avant : à un bout les chocs exogènes (invasion de l'Ukraine, 7 octobre, confinement), à l'autre les événements anticipés. La composante 2 est une montée qui culmine la veille du pic puis s'éteint (Noël, fins de campagne). La composante 3 est une bascule sèche : creux la veille, maximum le lendemain — la forme des scrutins, où le vocabulaire de campagne s'arrête au vote et celui des résultats démarre le lendemain. La composante 4 porte des rebonds à ± 7 jours, le rythme hebdomadaire de parution (rubriques revenant le même jour de la semaine).

Tranches de projection

Pour chaque composante, les fenêtres sont triées par leur projection et découpées en trois tranches par les quantiles 10 % et 90 % — les deux tranches extrêmes isolent les fenêtres qui ressemblent le plus à la composante (d'un côté et de l'autre), la tranche centrale rassemble les 80 % restants — puis on trace le profil moyen de chaque tranche.




Figure 2. – Profils moyens des fenêtres par tranche de projection sur chacune des quatre premières composantes. Tranches délimitées par les quantiles 10 % et 90 % des projections.

Fenêtres archétypes

Pour chaque composante, les quatre fenêtres réelles (seuil 6) dont la projection sur elle est la plus forte, parmi les mots du vocabulaire « parlant » (vocab600 étendu aux mots ajoutés) et **avec au moins 20 occurrences au pic** : sans ce plancher, des mots quasi absents de l'union (« dsk » après 2012, « annan », 2 à 7 occurrences au pic) prennent la tête de la composante 4 avec des formes de bruit. L'étiquette entre parenthèses situe le contexte du saut, posé à la main d'après les autres mots qui piquent le même




Figure 3. – Fenêtres archétypes (seuil 6) : les quatre sauts réels les plus alignés sur chacune des quatre premières composantes.

Fichiers du dossier

`composantes_etendu1j.npz` — les quatre premières composantes (31 valeurs chacune, axe `blocs` de -15 à +15) et leurs parts de variance, aux deux seuils.

`valeurs_propres_etendu1j.csv` — les 31 valeurs propres de la matrice de covariance des fenêtres z-scorées (convention $S^2/(n-1)$ après centrage des colonnes), une colonne par seuil ; $n = 108\,416$ fenêtres au seuil 4, 40 462 au seuil 6.

`projections_etendu1j.csv` — une ligne par fenêtre (mot, date, surprise) avec ses coefficients sur les quatre premières composantes, aux deux seuils ; chaque seuil ayant sa propre PCA, les colonnes `c*_s6` sont vides quand la surprise est entre 4 et 6.

`tops_mots_composantes_etendu1j.csv` — pour chaque seuil, chaque composante et chaque côté (projections les plus positives et les plus négatives), les quinze fenêtres les mieux alignées, avec un drapeau `parlant` (vocab600 étendu aux mots ajoutés, `vocab_parlant_etendu.txt`) pour filtrer les mots parlants.

Annexe — archétypes des deux côtés

Les composantes ont été orientées vers la queue lourde de leurs projections, et la figure des archétypes ne montre que ce côté-là. Une composante décrit pourtant une opposition : son côté négatif — la forme inversée — a lui aussi ses fenêtres réelles. Pour chaque composante, les deux fenêtres (seuil 6, parlant, ≥ 20 occurrences au pic) dont la projection est la plus positive, puis les deux dont elle est la plus négative.



Figure 4. – Fenêtres archétypes des deux côtés (seuil 6) : pour chaque composante, les deux sauts réels de projection la plus positive (à gauche) et les deux de projection la plus négative (à droite).