

Campagne PCA 48 h — hyperparamètres des fenêtres de sauts

Quatre médias, six salves, ~2 400 configurations (31/07–01/08/2026)

La question et le dispositif

La PCA du modèle zéro (Le Monde, fenêtres ± 15 jours, seuil de surprise 4) donnait un spectre plat : 33 % de variance à 6 composantes. La campagne évalue une fonction `PCA(média, grille, fenêtre, seuil, filtre, vocabulaire, transformation)` → qualité du spectre sur tout l'espace des réglages :

Axe	Valeurs explorées
média	Le Monde, Le Figaro, Les Échos, Mediapart (base ngram construite pour l'occasion, 53 095 articles 2008→2026)
grille	journalier, blocs de 3 jours, blocs de 7 jours de parution
demi-fenêtre	$\pm 5, \pm 10, \pm 15, \pm 25, \pm 35, \pm 50, \pm 70$ pas de grille
seuil de surprise	3, 4, 5, 6 (pics recalculés à $s \geq 3$ partout)
filtre grammatical	tous, sans verbes, noms seulement, noms propres (Lexique383 + spaCy sur les vocabulaires)
vocabulaire	top-10 000 par jours actifs ; variante $\geq 1\,000$ jours actifs (39 316 mots)
transformation	fréquences brutes ; $\log(1+f)$

Le runner (`rupture/campagne.py`) rejoue la fin de chaîne en mémoire (pics filtrés → NMS à portée $2d+1$ → fenêtres → nettoyage V2 → z-score par fenêtre → PCA) en 2 à 10 s par configuration. 1 753 configurations au balayage principal, 2 304 au balayage final à double témoin, toutes journalisées (`resultats.csv`, `resultats_rotation.csv`).

Mesurer honnêtement : les trois pièges

Le score naïf — la variance cumulée à 6 composantes — s'est révélé faux trois fois, et sa correction est le premier résultat de la campagne.

1. **La dimension.** Une fenêtre ± 5 vit dans 10 dimensions, une ± 50 dans 100 : à structure égale, la petite fenêtre « gagne » mécaniquement. Sous l'hypothèse nulle « la variance se répartit également entre les composantes », le nombre de composantes disponibles dépend structurellement de la taille de la fenêtre, et la variance cumulée à 6 composantes n'est donc plus une mesure comparable d'une fenêtre à l'autre. On utilise à la place $\text{gain}_6 = \text{cum}_6 / \text{cum}_6^{\text{attendu}}$ sous cette hypothèse nulle, qui compare le ratio entre ce qui est observé et ce qu'on attendrait sous l'hypothèse nulle : plus ce ratio est élevé, plus la variance réellement expliquée dépasse la variance attendue.
2. **Les marges et la petite matrice.** Une seconde hypothèse nulle : « les jours d'une même fenêtre ne sont pas réellement liés entre eux, seuls certains jours sont, en moyenne, plus ou moins variables que d'autres » (le jour du pic, par construction, plus agité que les bords). Si c'est vrai, on peut échanger au hasard les valeurs d'un même jour entre fenêtres différentes — par exemple le $j+3$ de la 14^e fenêtre avec le $j+3$ de la 5^e. La variance de chaque colonne ne bouge pas (on ne permute des valeurs qu'au sein d'une même colonne), mais la structure temporelle — le lien entre jours voisins d'une même fenêtre — est détruite. Si cette structure n'apportait aucune information, la variance cumulée resterait semblable avec ou sans ce mélange : on définit $\text{exces}_6 = \text{cum}_6 / \text{cum}_6^{\text{nul}}$,

où plus ce ratio est élevé, plus le lien réel entre jours pèse au-delà de cette simple inégalité de variance. Les scores spectaculaires des petites configurations (900 fenêtres, gain6 $\approx$ 6) retombent ainsi à 1,05 : c'était du bruit de petite matrice et des variances marginales, pas une vraie forme.

3. **La composition.** Les moyennes par axe mélangent effet et taille d'échantillon : les comparaisons se font à **n apparié** (5 000 fenêtres sous-échantillonnées, tirage seedé, 3 graines — dispersion inter-graines médiane 0,0045, tous les écarts commentés sont significatifs).

Enfin un second témoin, le **décalage circulaire de chaque fenêtre** (l'autocorrélation de la série est préservée, l'alignement sur le pic est détruit), sépare deux choses que **exces6** confond : la **texture** (de l'autocorrélation générique, présente n'importe où dans la série) et la **part ancrée sur l'événement** ($\text{alignement6} = \text{cum6}/\text{cum6}_{\text{rotation}}$).

Résultats par axe




Figure 1. — Effets des axes sur les deux métriques (brut, n apparié, grille équilibrée sur 39 cellules $\times$ 4 médias).

- **Média — l'effet le plus fort, et il s'inverse selon la métrique.** Texture : Figaro 1,28 > Monde 1,22 > Échos 1,17 > Mediapart 1,07. Part ancrée : **Mediapart 1,62** > Échos 1,44 > Monde 1,33 > Figaro 1,28.
- **Grille.** L'agrégation (3 j, 7 j) ajoute de la texture mais **floute l'alignement** : la part ancrée passe de 1,54 (journalier) à 1,12 (hebdo).
- **Fenêtre.** La part ancrée **croît fortement avec la fenêtre** (1,22 à $\pm 10 \rightarrow 1,70$ à ± 50) à texture quasi constante : autour d'un grand pic, la série porte des formes longues — les composantes montrent des **marches de régime** (plateau avant, pic, plateau après).
- **Seuil.** Même logique : s6 porte plus de forme ancrée que s4 (1,65 contre 1,31), à texture égale. Les grands pics ont de vraies silhouettes.
- **Filtre grammatical : quasi plat** à n apparié (1,36–1,39). Le filtre noms propres avait un léger avantage sur Le Monde seul ; il ne se généralise pas. Non décisif.
- **Vocabulaire : la queue dilue.** La variante $\geq 1\,000$ jours actifs (39 316 mots) fait perdre $0,084 \pm 0,026$ d'exces6 sur 76 paires appariées. Le top-10 000 est le bon choix.
- **Log : un levier, mais pour la texture seulement.** $\log(1+f)$ ajoute jusqu'à +0,76 d'exces6 (Figaro ± 50 : 1,61 $\rightarrow$ 2,37) mais ramène l'alignement à $\sim 1,0$ partout : il révèle l'autocorrélation lente et **noie les formes d'événement**.

La carte des médias




Figure 2. – Chaque point est un média × grille à la configuration de référence. La diagonale négative résume la campagne : la part ancrée s'échange contre la texture.

Deux profils de médias se dégagent. **Mediapart** : peu de structure totale, mais presque toute ancrée sur l'événement — ses composantes sont des pics « secs », sans montée ni retombée (90-100 % de l'énergie au centre). **Le Figaro** (et Le Monde agrégé) : beaucoup de structure, majoritairement de la texture lente. Les Échos journalier est le meilleur compromis des deux axes.

Recommandations

La « meilleure PCA » dépend de la question — c'est le message central.

Pour les formes d'événement (objectif : le dataset de sauts et leur classification) : **journalier, fréquences brutes, ± 25 à ± 50 , seuil 6**, top-10 000, tous les mots. C'est la configuration qui maximise la part ancrée (Mediapart : alignement6 = 2,58 ; Échos : 2,07) tout en gardant des effectifs sains. Le seuil 4 en variante pour l'effectif ($\times 3$), les filtres grammaticaux en option d'interprétation, pas de log.

Pour la texture et les régimes (objectif : les ruptures durables — la question des rachats) : **log(1+f), grilles agrégées, grandes fenêtres**, Figaro en tête. Ce qui était un « défaut » pour les formes d'événement est exactement le signal qu'un détecteur de breakpoints voudra.

Réserves et chantiers ouverts

- **Boilerplate Mediapart** : les extrêmes de ses composantes sont pollués par des mots d'interface (« articles », « phrases »...). Contrôle fait : les exclure ne change presque rien à la métrique (2,55 $\rightarrow$ 2,48), mais un nettoyage s'impose avant toute interprétation fine (chantier commun avec les stop words).

- **NMS couplé à la fenêtre** : la portée du dédoublement vaut la largeur de fenêtre ; comparer des fenêtres compare donc aussi des datasets. Le n apparié neutralise l'effet de taille, pas celui de sélection.
- **Kernel PCA** : non exploré — la priorité est allée aux témoins nuls, et la PCA linéaire n'est pas épuisée (les formes longues viennent d'être découvertes). À reprendre si la classification bute sur du non-linéaire.
- **Fenêtres par mot** (remarque Bouchot) et **périodes d'activité anormale** : hors périmètre, notées au to_do.

Reproduction

Tout est versionné dans [campagne_pca/](#) (GitHub) : runner ([rupture/campagne.py](#)), scripts de salves ([salve*.sh](#)), journal complet ([suivi.md](#)), récoltes ([resultats.csv](#), 1 753 configs ; [resultats_rotation.csv](#), 2 304 configs au double témoin), figures et scripts de figures. Les données intermédiaires (pics s3, séries 40k, base ngram Mediapart) sont sur gallica dans [data/](#).