

Campagne PCA 48 h — hyperparamètres des fenêtres de sauts

Quatre médias, six salves, ~2 400 configurations (31/07–01/08/2026)

La question et le dispositif

La PCA du modèle zéro (Le Monde, fenêtres ± 15 jours, seuil de surprise 4) donnait un spectre plat : 33 % de variance à 6 composantes. La campagne évalue une fonction `PCA(média, grille, fenêtre, seuil, filtre, vocabulaire, transformation)` → qualité du spectre sur tout l'espace des réglages :

Axe	Valeurs explorées
média	Le Monde, Le Figaro, Les Échos, Mediapart (base ngram construite pour l'occasion, 53 095 articles 2008→2026)
grille	journalier, blocs de 3 jours, blocs de 7 jours de parution
demi-fenêtre	$\pm 5, \pm 10, \pm 15, \pm 25, \pm 35, \pm 50, \pm 70$ pas de grille
seuil de surprise	3, 4, 5, 6 (pics recalculés à $s \geq 3$ partout)
filtre grammatical	tous, sans verbes, noms seulement, noms propres (Lexique383 + spaCy sur les vocabulaires)
vocabulaire	top-10 000 par jours actifs ; variante $\geq 1\,000$ jours actifs (39 316 mots)
transformation	fréquences brutes ; $\log(1+f)$

Le runner (`rupture/campagne.py`) rejoue la fin de chaîne en mémoire (pics filtrés → NMS à portée $2d+1$ → fenêtres → nettoyage V2 → z-score par fenêtre → PCA) en 2 à 10 s par configuration. 1 753 configurations au balayage principal, 2 304 au balayage final à double témoin, toutes journalisées (`resultats.csv`, `resultats_rotation.csv`).

Mesurer honnêtement : les trois pièges

Le score naïf — la variance cumulée à 6 composantes — s'est révélé faux trois fois, et sa correction est le premier résultat de la campagne.

1. **La dimension.** Une fenêtre ± 5 vit dans 10 dimensions, une ± 50 dans 100 : à structure égale, la petite fenêtre « gagne » mécaniquement. Sous l'hypothèse nulle « la variance se répartit également entre les composantes », le nombre de composantes disponibles dépend structurellement de la taille de la fenêtre, et la variance cumulée à 6 composantes n'est donc plus une mesure comparable d'une fenêtre à l'autre. On utilise à la place $\text{gain}_6 = \text{cum}_6 / \text{cum}_6^{\text{attendu}}$ sous cette hypothèse nulle, qui compare le ratio entre ce qui est observé et ce qu'on attendrait sous l'hypothèse nulle : plus ce ratio est élevé, plus la variance réellement expliquée dépasse la variance attendue.
2. **Les marges et la petite matrice.** Une seconde hypothèse nulle : « les jours d'une même fenêtre ne sont pas réellement liés entre eux, seuls certains jours sont, en moyenne, plus ou moins variables que d'autres » (le jour du pic, par construction, plus agité que les bords). Si c'est vrai, on peut échanger au hasard les valeurs d'un même jour entre fenêtres différentes — par exemple le $j+3$ de la 14^e fenêtre avec le $j+3$ de la 5^e. La variance de chaque colonne ne bouge pas (on ne permute des valeurs qu'au sein d'une même colonne), mais la structure temporelle — le lien entre jours voisins d'une même fenêtre — est détruite. Si cette structure n'apportait aucune information, la variance cumulée resterait semblable avec ou sans ce mélange : on définit $\text{exces}_6 = \text{cum}_6 / \text{cum}_6^{\text{nul}}$,

où plus ce ratio est élevé, plus le lien réel entre jours pèse au-delà de cette simple inégalité de variance. Les scores spectaculaires des petites configurations (900 fenêtres, gain6 $\approx$ 6) retombent ainsi à 1,05 : c'était du bruit de petite matrice et des variances marginales, pas une vraie forme.

3. **La composition.** Mécaniquement, exiger une surprise plus élevée ou restreindre le vocabulaire (par exemple ne garder que les noms propres) réduit drastiquement le nombre de fenêtres disponibles : sur Le Monde, ± 15 jours, tous les mots, on a 342 787 fenêtres à seuil 3 contre seulement 31 232 à seuil 6 — un facteur 11 rien qu'en changeant le seuil ; ne garder que les noms propres (à seuil 4) descend à 9 647 fenêtres. Comparer la moyenne d'excès6 par axe mélange donc, sans le vouloir, l'effet de l'axe étudié et celui de la taille d'échantillon qui varie avec lui. Les comparaisons se font donc à **n apparié** : on ramène systématiquement toute configuration à 5 000 fenêtres (tirage seedé) — une taille fixe, inférieure à la plus restrictive rencontrée (les 9 647 des noms propres), pour que tous les axes, pas seulement deux niveaux d'un même axe, restent comparables entre eux. Trois graines de tirage donnent une dispersion inter-graines médiane de 0,0045 : tous les écarts commentés dans le rapport sont significatifs au regard de ce bruit.

Enfin un second témoin, le **décalage circulaire de chaque fenêtre** (l'autocorrélation de la série est préservée, l'alignement sur le pic est détruit), sépare deux choses que excès6 confond : la **texture** (de l'autocorrélation générique, présente n'importe où dans la série) et la **part ancrée sur l'événement** (alignement6 = cum6/cum6_{rotation}).

Résultats par axe




Figure 1. – Effets des axes sur les deux métriques (brut, n apparié, grille équilibrée sur 39 cellules $\times$ 4 médias).

- **Média — l'effet le plus fort, et il s'inverse selon la métrique.** Texture : Figaro 1,28 > Monde 1,22 > Échos 1,17 > Mediapart 1,07. Part ancrée : **Mediapart 1,62** > Échos 1,44 > Monde 1,33 > Figaro 1,28.
- **Grille.** L'agrégation (3 j, 7 j) ajoute de la texture mais **floute l'alignement** : la part ancrée passe de 1,54 (journalier) à 1,12 (hebdo).
- **Fenêtre.** La part ancrée **croît fortement avec la fenêtre** (1,22 à $\pm 10 \rightarrow 1,70$ à ± 50) à texture quasi constante : autour d'un grand pic, la série porte des formes longues — les composantes montrent des **marches de régime** (plateau avant, pic, plateau après).
- **Seuil.** Même logique : s6 porte plus de forme ancrée que s4 (1,65 contre 1,31), à texture égale. Les grands pics ont de vraies silhouettes.
- **Filtre grammatical : quasi plat** à n apparié (1,36–1,39). Le filtre noms propres avait un léger avantage sur Le Monde seul ; il ne se généralise pas. Non décisif.
- **Vocabulaire : la queue dilue.** La variante $\geq 1\,000$ jours actifs (39 316 mots) fait perdre $0,084 \pm 0,026$ d'excès6 sur 76 paires appariées. Le top-10 000 est le bon choix.
- **Log : un levier, mais pour la texture seulement.** log(1+f) ajoute jusqu'à +0,76 d'excès6 (Figaro ± 50 : 1,61 $\rightarrow$ 2,37) mais ramène l'alignement à $\sim 1,0$ partout : il révèle l'autocorrélation lente et **noie les formes d'événement**.

La carte des médias




Figure 2. – Chaque point est un média × grille à la configuration de référence. La diagonale négative résume la campagne : la part ancrée s'échange contre la texture.

Deux profils de médias se dégagent. **Mediapart** : peu de structure totale, mais presque toute ancrée sur l'événement – ses composantes sont des pics « secs », sans montée ni retombée (90-100 % de l'énergie au centre). **Le Figaro** (et Le Monde agrégé) : beaucoup de structure, majoritairement de la texture lente. Les Échos journalier est le meilleur compromis des deux axes.

Recommandations

La « meilleure PCA » dépend de la question – c'est le message central.

Pour les formes d'événement (objectif : le dataset de sauts et leur classification) : **journalier, fréquences brutes, ± 25 à ± 50 , seuil 6**, top-10 000, tous les mots. C'est la configuration qui maximise la part ancrée (Mediapart : alignement6 = 2,58 ; Échos : 2,07) tout en gardant des effectifs sains. Le seuil 4 en variante pour l'effectif ($\times 3$), les filtres grammaticaux en option d'interprétation, pas de log.

Pour la texture et les régimes (objectif : les ruptures durables – la question des rachats) : **log(1+f), grilles agrégées, grandes fenêtres**, Figaro en tête. Ce qui était un « défaut » pour les formes d'événement est exactement le signal qu'un détecteur de breakpoints voudra.

Réserves et chantiers ouverts

- **Boilerplate Mediapart** : les extrêmes de ses composantes sont pollués par des mots d'interface (« articles », « phrases »...). Contrôle fait : les exclure ne change presque rien à la métrique (2,55 $\rightarrow$ 2,48), mais un nettoyage s'impose avant toute interprétation fine (chantier commun avec les stop words).

- **NMS couplé à la fenêtre** : la portée du dédoublement vaut la largeur de fenêtre ; comparer des fenêtres compare donc aussi des datasets. Le n apparié neutralise l'effet de taille, pas celui de sélection.
- **n apparié fixé à 5 000 : conservateur, mais sans coût mesuré.** Cette cible est bien en dessous de la plupart des configurations (jusqu'à 342 787 fenêtres à seuil 3) — une cible plus généreuse (8 000-9 000) aurait préservé plus de données. Contrôle fait sur la référence : [exces6](#) ne bouge que de 1,170 (n complet, 121 805) à 1,155 (n = 5 000), un écart négligeable face aux effets rapportés (0,05 à 0,7) — aucune conclusion n'aurait changé avec une cible plus haute. Les configurations les plus extrêmes (jusqu'à 79 fenêtres, Mediapart ± 70 /seuil 6/noms propres) restent de toute façon sous 5 000 et sont exclues des comparaisons plutôt que gonflées artificiellement.
- **Kernel PCA** : non exploré — la priorité est allée aux témoins nuls, et la PCA linéaire n'est pas épuisée (les formes longues viennent d'être découvertes). À reprendre si la classification bute sur du non-linéaire.
- **Fenêtres par mot** (remarque Bouchot) et **périodes d'activité anormale** : hors périmètre, notées au to_do.

Reproduction

Tout est versionné dans [campagne_pca/](#) (GitHub) : runner ([rupture/campagne.py](#)), scripts de salves ([salve*.sh](#)), journal complet ([suivi.md](#)), récoltes ([resultats.csv](#), 1 753 configs ; [resultats_rotation.csv](#), 2 304 configs au double témoin), figures et scripts de figures. Les données intermédiaires (pics s3, séries 40k, base ngram Mediapart) sont sur gallica dans [data/](#).