

PCA des sauts — catalogue des configurations

Le Monde, Le Figaro, Les Échos et Mediapart — les configurations qui gardent le plus de fenêtres à concentration comparable

Le Monde

LE FIGARO

LesEchos

MEDIAPART

La configuration optimale de `rapport.qmd` (Le Monde, hebdo, ± 10 blocs, seuil 6) concentre le mieux la variance, mais sur seulement 8 764 fenêtres. Les configurations ci-dessous en gardent davantage à concentration comparable — mesurée par **K50_frac**, la part du rang total qu'il faut pour atteindre 50 % de la variance, comparable d'une taille de fenêtre à l'autre (contrairement à K50 ou cum6 bruts). Deux familles : des grilles journalière et à 3 jours poussées au plus grand volume, puis une grille hebdomadaire commune aux quatre journaux. Chaque média garde sa couleur de charte (Le Monde : noir ; Le Figaro : bleu marine ; Les Échos : rouge sombre ; Mediapart : rouge-orangé).

Configurations à plus grand volume

Le Figaro apparaît dans les deux grilles : la journalière, qui le rend comparable aux Échos et à Mediapart, et celle à 3 jours, qui reprend exactement la géométrie du Monde (même fenêtre, seul le seuil change) et isole donc l'effet du média. Son corpus est le plus court des quatre (6 764 jours, 12/2004 – 03/2024) mais le plus dense au jour le jour (115 000 tokens en médiane, contre 57 000 pour Le Monde) : à seuil égal il rend donc moins de fenêtres que Le Monde malgré un volume quotidien deux fois supérieur.

	Monde (s. 6)	Monde (s. 5)	Figaro (3 j)	Figaro (jour.)	Échos	Mediapart
Grille	blocs de 3 j	blocs de 3 j	blocs de 3 j	journalier	journalier	journalier
Fenêtre	± 15 blocs	± 15 blocs	± 15 blocs	± 15 jours	± 12 jours	± 5 jours
Seuil	6	5	4	5	5	4
Fenêtres	14 102	24 593	18 375	17 939	21 073	20 237
K50_frac	0,23	0,27	0,30	0,30	0,29	0,20
cum6	47,6 %	43,3 %	40,1 %	42,1 %	46,6 %	84,0 %

La forme des sauts par configuration — trois premières composantes




Figure 1. — Trois premières composantes par configuration : Mediapart tranche nettement (deux composantes concentrent 51 % de la variance, un pic « sec ») quand les deux grilles du Monde restent plus étalées, à formes plus douces. Le Figaro est présenté à part, plus bas.

Le Monde, blocs de 3 jours

Configuration de référence du catalogue : les cinq vues de base, données une fois en entier ici — les autres configurations n'en reprennent que les deux qui comptent le plus (composantes, archétypes).




Figure 2. – Variance expliquée par composante, seuil 6 (14 102 fenêtres).




Figure 3. – Les six premières composantes.




Figure 4. – Les 14 102 fenêtres dans le plan des deux premières composantes.

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score),
 parmi les fenêtres d'au moins 56 occurrences au pic
 Le Monde, blocs de 3 jours, fenêtres ± 15 blocs (± 45 jours de parution), seuil de surprise 6




Figure 5. – Archétypes des quatre premières composantes.

Reconstruction de la fenêtre « jaunes » du 09/12/2018 (en gris) par les premières composantes (bleu)
 Le Monde, blocs de 3 jours, fenêtres ± 15 blocs (± 45 jours de parution), seuil de surprise 6




Figure 6. – Reconstruction d'une fenêtre réelle par les premières composantes.

Abaisser le seuil à 5 fait entrer 10 491 fenêtres de plus sans changer les formes : mêmes profils, composante 3 quasi identique (6,1 % de variance contre 6,6 %). Cette composante 3 mérite un détour : ni un pic ni une bascule mais un **doublet serré** — montée juste avant le pic, décrochage brutal au pic, puis plateau haut. Elle corrige

les fenêtres dont le maximum tombe un bloc *avant* la date retenue et dont la couverture repart ensuite sans redescendre.

Composante 3 : les 12 sauts réels les plus alignés (z-score), parmi les fenêtres d'au moins 56 occurrences au pic
Le Monde, blocs de 3 jours, fenêtres ± 15 blocs (± 45 jours de parution), seuil de surprise 6




Figure 7. – Composante 3, seuil 6 : les douze sauts réels les mieux projetés. Côte d'Ivoire fin 2010, l'identité nationale (11/2009), le confinement (03/2020), mai 1968.

Composante 3 : les 12 sauts réels les plus alignés (z-score), parmi les fenêtres d'au moins 50 occurrences au pic
 Le Monde, blocs de 3 jours, fenêtres ± 15 blocs (± 45 jours de parution), seuil de surprise 5




Figure 8. — Même composante à seuil 5 (24 593 fenêtres) : dix des douze archétypes sont les mêmes. Les deux entrants — « nettoyage » (Kosovo, 04/1999) et « îles » (Malouines, 04/1982) — confirment que la forme n'est pas un artefact du seuil.

Le Figaro

Deux réserves communes aux deux grilles. **Boilerplate** : la composante 2 aligne du texte de gabarit plutôt que des événements — crédit [Source](#) : AFP des brèves (11/2007 – 05/2008, jusqu'à 4 200 occurrences de « source ») et encart publicitaire [SERVICE >> bwin.fr](#) (09 – 12/2011, « service » triplé). Non nettoyé ici ; détail complet dans [rapport.qmd](#). **Encoche** : la composante 1 ne fait pas un pic au centre mais un creux — $-0,54$ au jour 0 en journalier, $-0,34$ au bloc central à 3 jours — encadré de deux bosses. Le motif résiste à l'agrégation, ce qui écarte un accident d'un jour isolé ; reste à trancher entre un décalage de la date attribuée aux articles et un vrai creux de collecte au moment des pics.

Les six premières composantes comme profils temporels
Le Figaro, blocs de 3 jours, fenêtres ± 15 blocs (± 45 jours de parution), seuil de surprise 4




Figure 9. – Blocs de 3 jours, seuil 4 (18 375 fenêtres) : encoche au bloc central.

Les six premières composantes comme profils temporels
Le Figaro, journalier, fenêtres ± 15 jours, seuil de surprise 5




Figure 10. – Journalier, seuil 5 (17 939 fenêtres) : même encoche au jour 0, sur les composantes 1, 3 et 4.

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score),
 parmi les fenêtres d'au moins 51 occurrences au pic
 Le Figaro, blocs de 3 jours, fenêtres ± 15 blocs (± 45 jours de parution), seuil de surprise 4




Figure 11. – Archétypes de la grille à 3 jours : la composante 2 aligne le texte de gabarit (crédit AFP, encart bwin), pas des événements.

Les Échos — journalier, seuil 5

Les six premières composantes comme profils temporels
Les Échos, journalier, fenêtres ± 12 jours, seuil de surprise 5




Figure 12. – Les six premières composantes (21 073 fenêtres).

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score),
 parmi les fenêtres d'au moins 50 occurrences au pic
 Les Échos, journalier, fenêtres ± 12 jours, seuil de surprise 5




Figure 13. – Archétypes des quatre premières composantes.

Mediapart — journalier, seuil 4

Réserve : « articles » et « phrases » remontent dans les archétypes bruts, mais ce ne sont pas du gabarit — 27 et 11 occurrences sur leur meilleur jour, sans plateau. Ce sont des mots ordinaires à faible effectif que le z-score, qui efface l'échelle, laisse épouser une composante ; le filtre de volume (occurrences au pic $\geq$ médiane, plancher 50) les écarte des archétypes affichés ci-dessous — Mediapart a le corpus le plus court des quatre journaux (~11 000 mots/jour), donc le plus sensible à ce filtre.

Les six premières composantes comme profils temporels
Mediapart, journalier, fenêtres ± 5 jours, seuil de surprise 4




Figure 14. — Les six premières composantes (20 237 fenêtres).

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score),
 parmi les fenêtres d'au moins 50 occurrences au pic
 Mediapart, journalier, fenêtres ± 5 jours, seuil de surprise 4




Figure 15. – Archétypes des quatre premières composantes, filtre de volume appliqué.

Une configuration hebdomadaire par journal

Même largeur de fenêtre (± 10 semaines) et même seuil (4) pour les quatre journaux, sur grille à la semaine : directement comparables, et chacun dépasse 5 000 fenêtres, y compris Mediapart, le corpus le plus court. L'agrégation à la semaine lisse déjà les jours creux, sans nettoyage supplémentaire. Les archétypes suivent la même règle de filtre de volume que ci-dessus (médiane du journal, plancher 50 occurrences), affiché sous chaque vignette.

	Le Monde	Le Figaro	Les Échos	Mediapart
Fenêtres	27 707	11 311	8 633	5 483
K50_frac	0,30	0,30	0,30	0,40
cum6	51,8 %	52,3 %	50,5 %	44,9 %

La forme des sauts par journal — trois premières composantes
Grille hebdomadaire, fenêtres ± 10 semaines, seuil 4




Figure 16. — Trois premières composantes par journal : la même encoche juste avant le pic, suivie d'un rebond net, sur les quatre. Le classement s'inverse par rapport à la grille journalière optimale — ici Mediapart est le moins concentré (cum6 45 %), Le Figaro le plus concentré (52 %).

Le Monde

Les six premières composantes comme profils temporels
Le Monde, blocs de 7 jours, fenêtres ± 10 blocs (± 70 jours de parution), seuil de surprise 4




Figure 17. – Les six premières composantes.

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score),
 parmi les fenêtres d'au moins 60 occurrences au pic
 Le Monde, blocs de 7 jours, fenêtres ± 10 blocs (± 70 jours de parution), seuil de surprise 4




Figure 18. – Archétypes des quatre premières composantes : des événements réels, étalés sur tout le corpus (1945 à 2020).

Les six premières composantes comme profils temporels
Le Figaro, blocs de 7 jours, fenêtres ± 10 blocs (± 70 jours de parution), seuil de surprise 4




Figure 19. – Les six premières composantes.

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score),
 parmi les fenêtres d'au moins 85 occurrences au pic
 Le Figaro, blocs de 7 jours, fenêtres ± 10 blocs (± 70 jours de parution), seuil de surprise 4




Figure 20. – Archétypes des quatre premières composantes : la composante 1 tombe entièrement sur mars 2020, semaine du confinement.

Les Échos

Les six premières composantes comme profils temporels
Les Échos, blocs de 7 jours, fenêtres ± 10 blocs (± 70 jours de parution), seuil de surprise 4




Figure 21. – Les six premières composantes.

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score),
 parmi les fenêtres d'au moins 58 occurrences au pic
 Les Échos, blocs de 7 jours, fenêtres ± 10 blocs (± 70 jours de parution), seuil de surprise 4




Figure 22. – Archétypes des quatre premières composantes.

Les six premières composantes comme profils temporels
Mediapart, blocs de 7 jours, fenêtres ± 10 blocs (± 70 jours de parution), seuil de surprise 4




Figure 23. – Les six premières composantes.

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score),
 parmi les fenêtres d'au moins 50 occurrences au pic
 Mediapart, blocs de 7 jours, fenêtres ± 10 blocs (± 70 jours de parution), seuil de surprise 4



Figure 24. – Archétypes des quatre premières composantes : les composantes 2 et 3 pointent sur « mardi » (23/03/2026) — artefact de nom de jour, pas un événement. Le plancher de 50 occurrences mord fort ici (médiane à 21 seulement), 764 fenêtres éligibles sur 5 483.

Figures calculées à la compilation depuis `campagne_pca/data/cache_pca/`. Logos officiels via Wikimedia Commons. Méthode complète : `campagne_pca/rapport_pdf/rapport.pdf`.