

PCA des sauts — corpus unifié

Les 36 médias traités (blocs de 3 jours, fenêtre ± 15 blocs), aux seuils 4 et 6

Ce document présente les résultats de la PCA sur le **corpus unifié**, c'est-à-dire l'ensemble des articles des **36 médias** disponibles. La période étudiée est 2008-2026. On travaille sur des blocs de 3 jours, avec des fenêtres de ± 15 blocs autour de chaque pic. Le vocabulaire est limité aux **10 000 mots** du top du *Monde*, classés par nombre de jours de présence.

La procédure reste la même que d'habitude. Pour chaque mot, on ajuste une loi BNB sur ses fréquences en deux phases (double fit) : la première repère les outliers, qui sont retirés, la seconde réajuste la loi sur le reste, de sorte que les pics ne contaminent pas le modèle. On appelle **pic** un bloc dont la fréquence est anormalement haute au regard de cette loi ; un seuil de surprise de 4 correspond à une probabilité inférieure à 10^{-4} , un seuil de 6 à 10^{-6} . Comme un même épisode produit souvent plusieurs blocs surprenants d'affilée, on applique par mot un **NMS** : les pics sont parcourus par surprise décroissante, et chaque pic retenu élimine ses voisins à moins d'une largeur de fenêtre, ce qui garantit que deux pics gardés n'ont jamais de fenêtres qui se recouvrent. Une fois obtenue la fenêtre de 31 blocs d'un pic, on en calcule le **z-score au sein de cette seule fenêtre** : on la centre sur sa propre moyenne et on la divise par son propre écart-type.

La mesure de pertinence de la PCA est la **concentration** (`K50_frac` dans les CSV de campagne) : la part des axes qu'il faut pour atteindre la moitié de la variance — plus elle est basse, plus les formes de sauts se résument à quelques profils.

	Unifié (seuil 4)	Unifié (seuil 6)
Pics détectés	82 887	31 815
Gardés par NMS	39 980	16 390
Fenêtres	38 856	15 903
Concentration	0,27	0,20

Pics par trimestre

Les années chargées ne sont pas des artefacts. Mars 2008 et mars 2026 sont les municipales : dans un corpus dominé par la presse régionale, « listes », « voix » ou « adjoint » piquent dans des centaines de communes à la fois. Mars 2020 est le confinement. 2008 cumule en plus le démarrage du panel et la crise financière.




Figure 1. – Pics par trimestre, avant NMS et après.

Composantes et archétypes

Les composantes sont les formes de saut élémentaires : chaque fenêtre réelle se décompose en une combinaison de ces profils. Les tracer aux deux seuils sert de contrôle — si les formes changeaient en passant de 4 à 6, c'est que la PCA lirait du bruit plutôt qu'une structure. Les archétypes qui suivent donnent la lecture concrète : pour chaque composante, les trois sauts réels qui lui ressemblent le plus.




Figure 2. – Les six premières composantes aux deux seuils.




Figure 3. – Fenêtres archétypes (seuil 6) : les trois sauts réels les plus alignés sur chacune des quatre premières composantes.

Sauts anticipés, sauts exogènes

Cette lecture reprend la figure 4 de l'article *Identifying new classes of financial price jumps with wavelets* (Aubrun, Morel, Benzaquen, Bouchaud — PNAS 2025), qui classe les sauts de prix boursiers selon l'asymétrie de l'activité autour du choc : les sauts **anticipés** (l'activité précède le choc), **endogènes** (symétrique) et **exogènes** (l'activité suit le choc).

On commence par construire un **score artisanal** qui permet de mesurer si l'activité se situe avant ou après le pic : on fait la moyenne de l'activité pour les 15 blocs précédant le pic, et de même pour les 15 blocs après le pic, puis on soustrait ces deux quantités. Si le résultat est positif, c'est que l'activité vit après le pic, négatif avant. On peut donc trier les fenêtres selon ce score artisanal.

Maintenant, considérons la projection des fenêtres sur la composante 1 de la PCA : c'est aussi une mesure, on peut parler de **score projeté**. Si on applique un tri à nos fenêtres selon ce score, on obtient un nouveau classement, et ces deux classements sont quasi similaires (corrélation de 0,9 aux deux seuils) : on peut en déduire que la composante 1 mesure en pratique de quel côté du pic se situe l'activité, et permet de séparer les fenêtres selon ce critère.

La figure applique alors la recette de l'article, en tranchant sur le score projeté : les fenêtres sont découpées en cinq tranches — les quantiles de l'article, 10 %, 35 %, 65 % et 90 %, qui isolent les extrêmes — et on moyenne les fenêtres de chaque tranche.

Pour les extrêmes : côté « saut anticipé » (l'activité monte puis s'éteint), on retrouve les fins de campagne des municipales (« sortant », « étiquette », « conseillers », mars 2008, 2014 et 2026) ; côté « saut exogène » (apparition soudaine, puis sujet qui s'installe), on retrouve le confinement (« virus », « précautions », « téléphonique », mars 2020).




Figure 4. – Profils moyens des fenêtres par tranche de projection sur la composante 1. Tranches délimitées par les quantiles 10 %, 35 %, 65 % et 90 % des projections.

Remarque : les corpus ne sont pas encore complets (Le Télégramme s'arrête en 2011, Sud-Ouest en 2018, Le Figaro en mars 2024, Les Échos en octobre 2024, et Le Monde — le contributeur le plus lourd — fin 2025).