

PCA des sauts — corpus unifié

Les 36 médias traités comme un seul journal, dans la configuration du Monde (blocs de 3 jours, fenêtre ± 15 blocs), aux seuils 4 et 6

Le **corpus unifié** additionne les 36 bases n-grammes du pipeline comme si tous les articles paraissaient dans un même journal : occurrences et totaux sommés jour par jour sur une grille calendaire (2008–2026), puis regroupés en **2 268 blocs de 3 jours** — 8,0 milliards de tokens, treize fois Le Monde seul. Le vocabulaire est le top-10 000 du Monde repris tel quel, et la chaîne celle du catalogue : BNB en double fit, pics à surprise $\geq$ seuil, NMS, fenêtres ± 15 blocs, z-score, PCA. Le seuil 6 s'obtient par simple filtrage du seuil 4 (le NMS du sous-ensemble coïncide avec le sous-ensemble du NMS — vérifié, 16 390 pics des deux façons).

La concentration est rapportée au rang total (30) : $\text{gain6} = \text{cum6} / (6/30)$, 1 = spectre plat ; K50_frac , part du rang pour la moitié de la variance ; rang_eff_frac , rang effectif sur rang total. À géométrie égale, l'unifié fait mieux que Le Monde aux deux seuils — son seuil 4 vaut le seuil 6 du Monde, et son seuil 6 garde plus de fenêtres que la configuration optimale du Monde.

	Unifié (s. 4)	Unifié (s. 6)	Monde (s. 4)	Monde (s. 6)
Pics détectés	82 887	31 815	76 267	20 850
Gardés par NMS	39 980	16 390	49 983	14 190
Fenêtres	38 856	15 903	49 771	14 102
cum6	44,8 %	51,9 %	37,9 %	47,6 %
gain6	2,24	2,59	1,90	2,38
K50_frac	0,27	0,20	0,33	0,23
rang_eff_frac	0,64	0,51	0,75	0,54

Pics par trimestre

Les années chargées ne sont pas des artefacts : mars 2008 et mars 2026 sont les municipales — dans un corpus dominé par la presse régionale, « listes », « voix » ou « adjoint » piquent dans des centaines de communes à la fois — et mars 2020 le confinement. 2008 cumule en plus le démarrage du panel et la crise financière.




Figure 1. – Pics détectés par trimestre : 82 887 au seuil 4, dont 31 815 au seuil 6.




Figure 2. – Après NMS : 39 980 pics (dont 16 390 au seuil 6), soit 48 % – contre 75 % sur Le Monde, les pics du corpus unifié étant plus rapprochés. Le dédoublement rabote surtout les trimestres denses, où les épisodes longs se réduisent à un représentant.

Composantes et archétypes




Figure 3. – Les six premières composantes aux deux seuils (signe aligné) : mêmes formes, le passage de 4 à 6 épure l'échantillon sans changer la structure.



Figure 4. – Fenêtres archétypes (seuil 6) : les trois sauts réels les plus alignés sur chacune des quatre premières composantes, parmi les 1 108 fenêtres dont le mot appartient au vocabulaire des matrices mot × mot (600 noms, noms propres et adjectifs à charge thématique). L'étiquette entre parenthèses situe le saut ; elle s'appuie sur les co-sauts du même bloc — les mots les plus surprenants à la même date, qui identifient l'événement sans ambiguïté : « l'invasion, sanctions, russie » derrière « guerre », « mensonge, jérôme » derrière « compte » (Cahuzac), « écoute, conversations » derrière « conseiller » (l'affaire des écoutes). Sur la composante 4, « santé » (29/08/2024) tombe sur le pire bloc de déversement de La Provence. Le point rouge marque le bloc du pic.

Deux réserves, mesurées et non corrigées à ce stade : la composition du corpus change au fil de la période (Le Télégramme s'arrête en 2011, Sud-Ouest en 2018, Le Figaro en mars 2024, Les Échos en octobre 2024), sans concentration visible des pics à ces dates ; et sur 119 blocs (5,2 %), un média déverse à lui seul plus de 10 % du corpus du bloc — les sept pires sont La Provence en 2024, en contenu santé.

Figures calculées à la compilation depuis `campagne_pca/data/pics_unifie/`. Chaîne et catalogue par média : `campagne_pca/rapport_pdf/`.