

PCA des sauts — corpus unifié

La réunion des 36 médias traitée comme un seul journal, dans la configuration du Monde (blocs de 3 jours, fenêtre ± 15 blocs), aux seuils 4 et 6

Le **corpus unifié** est la réunion des 36 bases n-grammes du pipeline, traitée comme un seul journal : les occurrences X_t et les totaux N_t sont sommés média par média, jour par jour, sur une grille **calendaire** (tous les jours du 01/01/2008 au 17/08/2026, soit 6 804 jours — on ne s’occupe plus des jours de parution), puis agrégés en **2 268 blocs de 3 jours** ; 8,0 milliards de tokens au total, environ treize fois Le Monde seul sur la même période. Le vocabulaire est le **top-10 000 du Monde repris tel quel** : mêmes mots, même ordre, si bien que chaque composante se compare colonne à colonne avec celles du Monde. La chaîne est celle du catalogue, inchangée : mélange Bernoulli $\times$ binomiale négative ajusté en double fit sur chaque mot, pics à surprise $\geq$ seuil, NMS glouton de portée 31 blocs, fenêtres ± 15 blocs, z-score par fenêtre, PCA. Deux seuils sont présentés : 4 (le défaut historique) et 6 (celui de la configuration optimale de [rapport.pdf](#)). Le passage de 4 à 6 se fait par simple filtrage : un pic à surprise ≥ 6 ne pouvant être supprimé que par un pic plus surprenant que lui, le NMS du sous-ensemble coïncide avec le sous-ensemble du NMS (vérifié : 16 390 pics dans les deux sens).

La concentration est mesurée **relativement au nombre de composantes** (31 blocs, rang utile 30) : $\text{gain6} = \text{cum6} / (6/30)$, le facteur gagné sur un spectre plat (1 = plat) ; K50_frac , la part du rang nécessaire pour 50 % de la variance ; rang_eff_frac , le rang effectif du spectre rapporté au rang total (1 = plat). À géométrie identique, le corpus unifié concentre mieux que Le Monde aux deux seuils, et son seuil 4 vaut à peu près le seuil 6 du Monde.

	Unifié (s. 4)	Unifié (s. 6)	Monde (s. 4)	Monde (s. 6)
Pics détectés	82 887	31 815	76 267	20 850
Gardés par NMS	39 980	16 390	49 983	14 190
Fenêtres	38 856	15 903	49 771	14 102
cum6	44,8 %	51,9 %	37,9 %	47,6 %
gain6	2,24	2,59	1,90	2,38
K50_frac	0,27	0,20	0,33	0,23
rang_eff_frac	0,64	0,51	0,75	0,54

Détection des pics, trimestre par trimestre




Figure 1. – Pics détectés par trimestre (82 887 au seuil 4, dont 31 815 au seuil 6). Les trois sur-densités sont des événements réels : les municipales de mars 2008 et de mars 2026 — le corpus est dominé par la presse régionale, qui couvre chaque commune —, et le confinement de mars 2020. L’année 2008 reste globalement plus dense : le panel démarre et l’actualité (campagne américaine, crise financière) s’y ajoute.




Figure 2. – Pics gardés par le NMS (39 980 au seuil 4, dont 16 390 au seuil 6) : le dédoublement garde 48 % des pics — contre 75 % sur Le Monde en blocs de 3 jours, les pics du corpus unifié étant plus rapprochés — et rabote surtout les trimestres denses, où les épisodes longs se réduisent à un représentant.

Spectre et composantes




Figure 3. – Variance expliquée par composante (échelle log). Le seuil 6 concentre davantage (cum6 51,9 % contre 44,8 %), tout en gardant 15 903 fenêtres — plus que la configuration optimale du Monde (14 102).




Figure 4. – Les six premières composantes aux deux seuils (signe aligné, le signe d’une composante étant arbitraire) : les formes sont les mêmes, le seuil ne fait que renforcer leur poids — le passage de 4 à 6 épure l’échantillon sans changer la structure.

Deux réserves sur les données, mesurées et non corrigées à ce stade. **Bascules de panel** : la composition du corpus change au fil de la période (Le Télégramme s’arrête en 2011, Sud-Ouest en 2018, Le Figaro en mars 2024, Les Échos en octobre 2024) ; les pics ne se concentrent pas visiblement à ces dates, mais l’effet reste à borner. **Déversements** : sur 119 blocs (5,2 %), un média publie à lui seul plus de 10 % du corpus du bloc — les sept pires sont La Provence en 2024, jusqu’à 33 % d’un bloc en contenu santé — et 8,6 % des pics gardés y tombent.

Figures calculées à la compilation depuis `campagne_pca/data/pics_unifie/`. Chaîne et catalogue par média : `campagne_pca/rapport_pdf/`.