

Kernel PCA des fenêtres de sauts

Le noyau RBF n'a jamais concentré la variance mieux que la PCA linéaire
— Le Monde, Le Figaro, Les Échos, Mediapart

Le Monde

LE FIGARO

LesEchos

MEDIAPART

La question

La PCA linéaire des fenêtres de sauts laisse un spectre étalé : sur la configuration de référence (± 15 jours, seuil 4), six composantes n'expliquent que 33 % de la variance au Monde et 34 % aux Échos, contre 20 % pour un nuage sans structure. Une **kernel PCA** — qui projette d'abord les fenêtres dans un espace plus riche, où des structures courbes deviennent des directions droites — resserrerait-elle ce spectre ?

Réponse : **non**, sur les quatre journaux et les trois grilles testées (journalière, 3 jours, 7 jours). Le noyau RBF étale la variance au lieu de la concentrer, et l'écart se creuse à mesure qu'il devient plus non linéaire.

Méthode

Même chaîne que le reste de la campagne (pics filtrés au seuil de surprise, NMS, découpe des fenêtres, z-score par fenêtre), puis deux décompositions comparées sur la même matrice : la PCA linéaire habituelle, et une kernel PCA à noyau gaussien $K_{ij} = \exp(-\gamma \|z_i - z_j\|^2)$, doublement centrée. Le noyau compare chaque fenêtre à toutes les autres — coût en n^2 , jusqu'à 120 Go sur la grille journalière du Monde (123 310 fenêtres). D'où un échantillon de 8 000 fenêtres sur cette grille ; les grilles hebdomadaire et à 3 jours, bien plus petites, passent en entier.

γ fixe la distance à partir de laquelle deux fenêtres cessent de se ressembler : petit, on retombe sur la PCA linéaire ; grand, chaque fenêtre ne ressemble plus qu'à elle-même et le spectre s'aplatit. Il est calé sur l'échelle réelle des distances, $\gamma_{\text{méd}} = 1/(2 \cdot \text{médiane}(\|z_i - z_j\|^2))$, médiane estimée sur 4 millions de paires tirées au hasard, puis balayé sur $\gamma_{\text{méd}} \times [0, 1 \dots 30]$. Un témoin de bruit blanc (même z-score, aucune structure temporelle) accompagne chaque test : toute concentration qu'il afficherait ne mesurerait rien de réel.

Le piège du dénominateur

Le premier passage concluait à un gain net : la composante 1 passait de 9,3 % à 13,8 % au Monde, de 10,5 % à 17,3 % aux Échos, grandissant avec γ jusqu'à plus de 40 %. Ce résultat était **faux**.

La kernel PCA ne retient qu'un nombre fixé de composantes — 30 ici, le rang d'une fenêtre de dimension 31. Diviser leur variance par leur propre somme donne la part de la composante 1 *parmi les 30 retenues*, pas sa part de la variance totale : dans l'espace induit par le noyau, le rang monte jusqu'à n , pas 30. Le bon dénominateur est la trace de la matrice de Gram centrée. L'écart n'est pas anecdotique : au Monde, à $\gamma = 1/D$, les 30 composantes retenues ne pèsent que 67 % de la variance totale ; à $\gamma = 1$, 4,6 % seulement.

Le même calcul lu de deux façons : diviser par la somme des seules composantes retenues
fabrique un gain qui disparaît dès qu'on rapporte à la variance totale




Figure 1. – À gauche, la lecture fautive : la variance cumulée des six premières composantes semble grimper avec γ et dépasser la PCA linéaire (pointillés). À droite, le même calcul rapporté à la variance totale : la courbe descend, le noyau ne fait jamais mieux que le linéaire.
Le témoin de bruit blanc (gris) tranche : à gauche il reste plat autour de 21 %, à droite il s'effondre vers 0 comme il se doit.

Résultats

Grille journalière — Le Monde et Les Échos (échantillon de 8 000 fenêtres)

	Le Monde	Les Échos
Composante 1 — linéaire	9,3 %	10,5 %
Composante 1 — kernel ($\gamma=1/D$)	9,3 %	11,8 %
cum6 — linéaire	33,0 %	34,3 %
cum6 — kernel ($\gamma=1/D$)	24,9 %	27,2 %
cum6 — kernel ($\gamma=0,1$)	16,3 %	20,2 %
cum6 — kernel ($\gamma=1$)	2,5 %	5,6 %

La composante 1 est au mieux marginalement meilleure — identique au Monde, +1,3 point aux Échos — mais dès la deuxième composante le noyau décroche, et l'écart se creuse avec γ .

Variancé expliquée par composante : la kernel PCA ne concentre pas mieux
fenêtres ± 15 jours seuil de surprise 4 échantillon de 8 000 fenêtres




Figure 2. – Les deux spectres superposés à $\gamma = 1/D$. Passé le premier rang, la courbe kernel (bleu) reste sous la courbe linéaire sur toute la longueur du spectre : la variance est répartie sur davantage de directions, pas moins.

Grille hebdomadaire — Mediapart, Les Échos, Le Figaro

Même fenêtre (± 10 blocs, $D = 21$) et même seuil (4) pour les trois journaux ; γ calé par média sur la distance médiane réelle.

	Mediapart	Les Échos	Le Figaro
Fenêtres	5 483	8 633	11 311
$\gamma_{\text{méd}}$	0,0501	0,0347	0,0299

	linéaire	$0,1 \cdot \gamma_{\text{méd}}$	$\gamma_{\text{méd}}$	$30 \cdot \gamma_{\text{méd}}$
Mediapart — 5 483 fenêtres, $\gamma_{\text{méd}} = 0,0501$				
comp1 (%)	12,81	12,46	11,04	3,25
K50	8	8	11	1 764
K90	17	18	136	4 050
Les Échos — 8 633 fenêtres, $\gamma_{\text{méd}} = 0,0346$				
comp1 (%)	14,76	14,36	11,59	1,25
K50	6	7	10	3 284
K90	17	18	116	6 912
Le Figaro — 11 311 fenêtres, $\gamma_{\text{méd}} = 0,0299$				
comp1 (%)	14,12	13,69	10,73	1,01
K50	6	6	9	4 139
K90	17	18	114	8 936

Figure 3. – Sur les 9 comparaisons (3 journaux $\times$ 3 γ), comp1 kernel ne dépasse jamais comp1 linéaire. K90 explose d'un facteur 200 à 500 dès le régime dégénéré.

Grille à 3 jours — mêmes trois journaux

Même fenêtre (± 10 blocs), seuil relevé à 5.

	Mediapart	Les Échos	Le Figaro
Fenêtres	4 665	8 188	9 676
$\gamma_{\text{méd}}$	0,0813	0,0470	0,0355

	linéaire	$0,1 \cdot \gamma_{\text{méd}}$	$\gamma_{\text{méd}}$	$30 \cdot \gamma_{\text{méd}}$
Mediapart — 4 665 fenêtres, $\gamma_{\text{méd}} = 0,0813$				
comp1 (%)	11,13	11,11	13,49	6,24
K50	8	8	12	1 130
K90	17	19	173	3 042
Les Échos — 8 188 fenêtres, $\gamma_{\text{méd}} = 0,0470$				
comp1 (%)	15,89	15,51	13,46	2,90
K50	6	7	10	2 641
K90	17	18	131	6 078
Le Figaro — 9 676 fenêtres, $\gamma_{\text{méd}} = 0,0355$				
comp1 (%)	16,20	15,76	12,87	2,11
K50	6	6	9	3 264
K90	17	18	109	7 389

Figure 4. – Sur les 9 comparaisons, Mediapart est seul à voir comp1 kernel dépasser comp1 linéaire (13,49 % contre 11,13 % à $\gamma_{\text{méd}}$) ; Les Échos et Le Figaro reproduisent le schéma habituel.

Le dépassement sur Mediapart — le corpus le plus petit et le plus bruité des trois — reste à confirmer avant d’y voir un signal plutôt qu’un effet d’échantillon.

Pourquoi c’était prévisible

Le noyau RBF projette les données dans un espace de dimension infinie, où les points s’éloignent les uns des autres : la variance s’y répartit sur beaucoup plus de directions, l’inverse d’une concentration. Il ne resserre un spectre que si les données vivent sur une surface courbe de basse dimension — un nuage enroulé en spirale, deux groupes séparés par une frontière incurvée — qu’il peut « déplier ». Rien de tel ici : le nuage des fenêtres reste le même continuum d’un journal à l’autre, une amplitude et une largeur qui varient autour de la même forme de saut, sans groupe distinct ni courbure à révéler.

Le nuage des fenêtres dans le plan des deux premières composantes :
même continuum, aucun groupe que le noyau ferait apparaître




Figure 5. — Le nuage des 8 000 fenêtres dans le plan des deux premières composantes, linéaire à gauche, kernel à droite. Les échelles diffèrent — les projections kernel ne sont pas dans les unités des fenêtres — mais la géométrie est la même : un continuum, pas des groupes.

Le coût, même en cas de gain

La kernel PCA n'aurait de toute façon pas été gratuite à adopter. Ses composantes vivent dans l'espace induit par le noyau, pas dans celui des jours de la fenêtre : elles ne se tracent pas comme des profils temporels, et trois des cinq figures qui font l'interprétation de la campagne — profils de composantes, fenêtres archétypes, reconstruction progressive — n'ont pas d'équivalent direct. Il aurait fallu un gain franc pour justifier de perdre l'interprétabilité ; il n'y en a pas.

Réserves

- **Échantillon journalier.** Le test porte sur 8 000 fenêtres tirées au hasard, contre 123 310 (Monde) et 48 336 (Échos) pour la PCA linéaire complète. Les chiffres linéaires du tableau sont recalculés sur ce même échantillon, donc comparables entre eux ; ils diffèrent de quelques dixièmes de ceux du rapport principal.
- **Une seule famille de noyaux.** Seul le RBF a été balayé. Un noyau polynomial de degré 2 ou 3, qui n'envoie pas en dimension infinie, se comporterait différemment — mais rien dans la forme du nuage ne le rend prometteur.
- **Le z-score reste en amont :** il efface déjà l'échelle et une partie de la non-linéarité, un choix acté de la chaîne et non une variable de ce test.
- **Mediapart à 3 jours :** seul cas où le kernel dépasse le linéaire sur la composante 1, à confirmer sur un tirage indépendant avant d'en tirer une conclusion.

Conclusion

Le spectre étalé de la PCA des fenêtres n'est pas un artefact de linéarité : il reflète une vraie diversité de formes de sauts. Passer à un noyau ne le resserre pas, l'étale davantage, et coûterait l'interprétabilité des composantes — sur les quatre journaux et les trois grilles testées. La PCA linéaire reste le bon outil pour cette chaîne.

*Figures produites par `campagne_pca/scripts/figures.py` (commande `kernel`) et `campagne_pca/scripts/kernel_grille.py`. Logos officiels via *Wikimedia Commons*. Méthode complète de la chaîne : `campagne_pca/rapport_pdf/rapport.pdf`.*