

Des articles aux sauts lexicaux : chaîne de traitement et modèle zéro

Le Monde, 1944-2025 — phase 3 du mémoire

Le Monde

Objectif

Question de recherche du mémoire : *les rachats de journaux français modifient-ils la couverture thématique ?* Avant de comparer des journaux et des dates de rachat, il faut un instrument capable de repérer et de décrire **tous** les moments où un mot « saute » dans un journal.

La phase 3 construit cet instrument sur Le Monde (26 917 jours de parution, décembre 1944 à 2025) : détecter les sauts de chaque mot, en faire des *datapoints* comparables, puis chercher à l'aveugle — sans savoir quel mot ni quelle date — quelles **formes** de sauts existent. C'est le « modèle zéro » : les mots ne sont que des courbes, et on laisse les données parler avant d'y remettre du sens.

La chaîne

#	Étape	Script	Sortie	Volume
1	Choisir le vocabulaire	<code>scan_vocab.py</code>	top-10 000 mots	441 081 mots scannés
2	Extraire les séries	<code>masse.py</code>	matrice jours × mots	26 917 × 10 000
3	Détecter les pics	<code>pics_masse.py</code>	liste (mot, jour, p-valueur)	164 254 pics
4	Dédoublonner (NMS)	<code>nms.py</code>	un représentant par événement	123 465 gardés
5	Découper les fenêtres	<code>fenetres_masse.py</code>	matrice des fenêtres ±15 j	123 310 × 31
6	PCA	<code>pca.py</code>	composantes, projections	31 × 31

Chaque étape lit la sortie de la précédente (scripts dans *rupture/*) ; tout tourne sur le serveur en quelques secondes à quelques minutes. Les choix de vocabulaire — unité = la graphie, top-10 000 par nombre de jours actifs, fusion des doublons OCR — sont détaillés dans le journal des 21-22/07.

Étape 3 — détection des pics

Pour chaque mot, on compte ses occurrences jour par jour : X_t occurrences sur N_t mots publiés. On ajuste une loi décrivant le comportement *habituel* du mot — un mélange : probabilité p_0 de ne pas apparaître, sinon une binomiale négative proportionnelle à N_t . Un jour est déclaré **pic** quand le comptage observé serait quasi impossible sous cette loi : $p_t < 10^{-4}$. On appelle **surprise** la quantité $-\log_{10}(p_t)$; surprise 4 = seuil de détection, surprise 40 = jour astronomiquement anormal.

Sur les 10 000 mots : **164 254 pics**, 9 817 mots avec au moins un pic, 11 mots dont l'ajustement échoue et qui sont consignés.

Étape 4 — un événement, un datapoint

Un événement qui dure produit des dizaines de jours-pics d'affilée ; sans traitement, il entrerait des dizaines de fois dans l'analyse. L'idée naïve — fusionner de proche en proche les pics rapprochés, garder le meilleur de chaque

paquet — souffre du **chaînage** : un pont de pics espacés de moins de 31 jours soude des *années* en un seul bloc. Sur nos données, 164 groupes géants de ce type ; « syrienne » aurait fondu 760 jours de parution (2012-2014) en un point unique.

La solution retenue est la *non-maximal suppression* gloutonne, héritée de la détection d'objets en vision par ordinateur : trier les pics du mot par surprise décroissante, garder le plus surprenant, supprimer ses voisins à moins de 31 jours de parution **de lui**, recommencer. Un pic supprimé ne supprime personne : la suppression ne se propage pas, donc pas de groupe géant. Et 31 jours étant la largeur d'une fenêtre, deux représentants gardés n'ont jamais de fenêtres qui se chevauchent.




Figure 1. — « syrienne » 2011-2014 : pics détectés (bleu), représentants gardés par le NMS (cercles rouges) — un par sous-événement de la guerre civile, là où le chaînage n'en gardait qu'un seul au total.

Contre-vérification indépendante par `scipy.signal.find_peaks` : résultat identique sur 9 771 mots sur 9 817, les écarts restants étant des égalités de surprise départagées différemment. Bilan : **123 465 représentants**, un pic détecté sur quatre était un doublon de fenêtre.

Étape 5 — mise à l'échelle des fenêtres

Autour de chaque représentant, on découpe la fenêtre des fréquences f_t sur ± 15 jours de parution : une courbe de 31 points, un datapoint. On ne peut pas comparer directement la fenêtre de « guerre » et celle de « francisco » : l'analyse ne verrait que « certains mots sont plus fréquents que d'autres ». Chaque fenêtre est donc **normalisée sur elle-même** en z-score — on soustrait sa moyenne, on divise par son écart-type, il ne reste que la forme.

C'était l'objet d'une mise en garde de Benoît : l'option de normalisation intégrée des fonctions de PCA standardise *colonne par colonne*, ce qui ne supprime pas les écarts de niveau entre fenêtres.




Figure 2. – Variance expliquée par composante pour les trois normalisations (grille journalière, V2). Le témoin « colonne par colonne » écrase tout sur une première composante artificielle ; le z-score par fenêtre étale la variance sur des formes réelles.

Avec l'option colonne par colonne, la première composante capte à elle seule plus de 60 % de la variance et sa projection est corrélée à 0,99 au niveau moyen brut de la fenêtre : elle mesure « le mot est-il fréquent », pas la forme du saut. Cette variante est conservée comme témoin négatif.

Étape 6 — quelles formes de sauts existent ?

La PCA cherche les profils temporels qui expliquent le mieux les différences entre les fenêtres. Deux constats.

Le spectre est plat : les six premières composantes ne portent qu'un tiers de la variance, et il en faut quinze pour atteindre 62 %. Le repère qui donne sa force à ce constat : la 31e valeur propre étant nulle par construction (une fenêtre z-scorée a une somme nulle), le nuage vit dans 30 dimensions ; un nuage **sans aucune structure** donnerait donc 3,33 % par composante. Il n'existe pas deux ou trois formes archétypales qui résumeraient les sauts : la diversité des fenêtres est réelle, et c'est le premier résultat du modèle zéro.

Les premières formes sont simples et lisibles.

Les six premières composantes comme profils temporels
Le Monde, journalier, fenêtres ± 15 jours, seuil de surprise 4




Figure 3. – Les six premières composantes comme profils temporels.

Dans le plan des deux premières composantes, les événements historiques se placent là où on les attend : les épisodes longs et soutenus du côté « activité durable », la masse des petits pics isolés de l'autre.

```
(plan) francisco 04/1945 : PC1=+1.7 PC2=-0.1
(plan) algérie 03/1962 : PC1=+2.1 PC2=-2.4
(plan) mitterrand 05/1988 : PC1=+0.3 PC2=+1.8
(plan) chirac 05/1995 : PC1=-0.6 PC2=+0.1
(plan) attentats 11/2015 : PC1=+3.8 PC2=-2.4
(plan) jaunes 12/2018 : PC1=+3.1 PC2=-0.4
(plan) « covid » absent de cette configuration
(plan) syrienne 04/2017 : PC1=+1.4 PC2=-1.1
```

Les 121 805 fenêtres dans le plan des deux premières composantes
Le Monde, journalier, fenêtres ± 15 jours, seuil de surprise 4




Figure 4. – Les fenêtres dans le plan des composantes 1-2 (densité en bleu, échelle log). Points rouges : la fenêtre la plus surprenante de quelques mots-événements.

Les fenêtres réelles les plus alignées sur chaque composante confirment la lecture, et datent des jours qu'on reconnaît.

```
(archetypes) comp 1 : régimes 20071112 (63 occ.), l'affaire 20180724 (60 occ.), intérim
20000102 (18 occ.)
(archetypes) comp 2 : bronze 20040830 (30 occ.), finale 20240811 (126 occ.), médaille
20240811 (63 occ.)
(archetypes) comp 3 : israéliens 20081229 (42 occ.), étape 20160703 (25 occ.), juin 20160605
(378 occ.)
(archetypes) comp 4 : maîtrise 19741023 (35 occ.), planète 19650602 (40 occ.), musiciens
19670110 (14 occ.)
```

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score)
Le Monde, journalier, fenêtres ± 15 jours, seuil de surprise 4




Figure 5. – Pour chaque composante, les trois sauts réels les plus alignés.

Reconstruction de la fenêtre « jaunes » du 08/12/2018 (en gris) par les premières composantes (bleu)
Le Monde, journalier, fenêtres ± 15 jours, seuil de surprise 4




Figure 6. – Reconstruction d'une fenêtre réelle (« jaunes », gilets jaunes) par les premières composantes.

Deux contrôles, et un nettoyage (V2)

Deux contrôles menés sur l'analyse ont chacun appris quelque chose — détaillés dans le journal des 21-22/07 :

L’hypothèse « rythme hebdomadaire » est fausse. Les composantes 5-6 ressemblaient à une paire d’oscillations calées sur la semaine ; testé et infirmé (phase sans lien avec le jour de la semaine du pic). Ce sont des modes oscillants génériques.

La composante 4 avait débusqué un artefact de données, corrigé depuis par la V2 de la chaîne ([rupture/pca.py](#), nettoyage des jours à corpus quasi vide — 321 jours à moins de 5 000 mots publiés, $f_t = X_t/N_t$ y explosant). Les figures ci-dessus sont déjà la V2 : dans chaque fenêtre, ces jours sont interpolés depuis leurs voisins sains, et les fenêtres dont le jour *central* est lui-même quasi vide sont écartées.

Critère	V1 (brute)	V2 (nettoyée, ci-dessus)
Enrichissement corpus-vide de la comp. 4	×17,8	×0,5 (disparu)
Spectre (6 premières, %)	9,1 / 5,9 / 5,0 / 4,8 / 4,2 / 3,7	9,2 / 6,2 / 5,3 / 4,6 / 4,2 / 3,8
Stabilité des composantes ($ \cos $ V1-V2)	—	≥ 0,94 sur les six premières
Archétypes de la comp. 4	jours à 177 mots (artefact)	« désastre », 19/03/2011 (Fukushima)

Seule la direction qui portait l’artefact se réorganise (18,7° d’angle, contre moins de 3° pour les autres) ; le spectre et les profils restent en place. Les conclusions du modèle zéro sont donc robustes au nettoyage, ce qui les consolide — validation complète dans le journal du 22/07.




Figure 7. – Après nettoyage V2 : part de fenêtres à projection extrême sur la composante 4, selon le jour le plus creux de la fenêtre. L’enrichissement qui existait en V1 (×17,8) a disparu.

Changer d’échelle : blocs de 3 jours, puis d’une semaine

La chaîne entière a été rejouée sur des timelines agrégées ([rupture/agreger.py](#)) : les jours de parution regroupés par 3, puis par 7, consécutifs et non chevauchants — X et N sommés par bloc, date du bloc = jour du milieu, même vocabulaire de 10 000 mots. Aucun autre réglage ne change : les scripts aval tournent tels quels, et les fenêtres couvrent ±15 *blocs*, soit ±45 puis ±105 jours de parution.

Étape	journalier	3 jours	7 jours
Grille	26 917 jours	8 972 blocs	3 845 blocs
Pics détectés	164 254	76 267	44 955

Étape	journalier	3 jours	7 jours
Gardés après NMS	123 465	49 983	26 784
Fenêtres	123 310	49 771	26 457
Mots avec au moins un pic	9 817	8 514	7 028

L’artefact corpus-vide disparaît par construction. Le plus petit bloc de 3 jours pèse 17 785 mots, le plus petit bloc de 7 jours 55 684 — contre un seuil journalier de 5 000 : chaque jour pathologique est noyé dans un bloc avec des voisins sains. Une seule version est donc livrée pour ces grilles, tout seuil de nettoyage y donnant un résultat identique bit à bit.

Les formes sont les mêmes aux trois échelles. Les composantes 1-2-3 de la grille 3 jours retrouvent leurs homologues journalières à 0,98, 0,92 et 0,90 de cosinus, la 4 à 0,85 ; en hebdomadaire, 0,97, 0,96, 0,98 et 0,80. Seules les composantes 5 et 6 échangent leur rang, à l’identique sur les deux grilles agrégées. Le pic isolé, l’installation durable, la bascule avant/après existent à l’échelle du jour comme à celle de la semaine : ces formes ne sont pas un artefact de l’échantillonnage journalier.

Le spectre reste plat, et se concentre légèrement plus l’échelle grossissant : 33,3 %, 37,9 %, 41,2 % à $K = 6$ pour journalier/3j/7j — mais toujours 8 composantes au-dessus de l’isotropie à 3,33 %, pas de typologie des sauts à ces échelles non plus. Le témoin « colonne par colonne » monte lui à 75,9 % et 81,5 % de variance sur sa première composante.




Figure 8. — Les six premières composantes sur la grille 3 jours.

(archetypes) comp 1 : riches 20121122 (70 occ.), préciser 19510312 (15 occ.), compétences 20180326 (61 occ.)

(archetypes) comp 2 : washington 20010912 (540 occ.), unis 20010912 (1196 occ.), terroriste 20010912 (183 occ.)

(archetypes) comp 3 : temps 20200505 (416 occ.), hussein 19910224 (234 occ.), grande 19561101 (167 occ.)

(archetypes) comp 4 : alliés 19501230 (41 occ.), roy 19660926 (90 occ.), aventures 19961228 (29 occ.)

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score)
 Le Monde, blocs de 3 jours, fenêtres ± 15 blocs (± 45 jours de parution), seuil de surprise 4




Figure 9. – Fenêtres archétypes de la grille 3 jours : les trois sauts réels les plus alignés sur chaque composante.

Les six premières composantes comme profils temporels
 Le Monde, blocs de 7 jours, fenêtres ± 15 blocs (± 105 jours de parution), seuil de surprise 4




Figure 10. – Les six premières composantes sur la grille hebdomadaire.

(archetypes) comp 1 : renaissance 20230721 (75 occ.), opposés 20051223 (43 occ.), comédie 19600309 (46 occ.)

(archetypes) comp 2 : américains 20010914 (1239 occ.), terroriste 20010914 (327 occ.), gaza 20231013 (692 occ.)

(archetypes) comp 3 : rhône 19870505 (113 occ.), candidats 20170609 (690 occ.), grecs 19640810 (56 occ.)

(archetypes) comp 4 : remède 20200424 (26 occ.), due 20200501 (150 occ.), l'arrêt 20200417 (111 occ.)

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (z-score)
 Le Monde, blocs de 7 jours, fenêtres ± 15 blocs (± 105 jours de parution), seuil de surprise 4




Figure 11. – Fenêtres archétypes de la grille hebdomadaire.

Deux réserves. Moitié moins de datapoints en 3 jours (49 771 : les sous-événements distants de moins de 93 jours de parution fusionnent sous le NMS), et la phase du découpage — quel jour ouvre le premier bloc — est arbitraire ; un contrôle en décalant le découpage de 1 et 2 jours reste à faire. Surtout, l'agrégation agit comme un **filtre passe-bas sur la détection elle-même** : un pic d'un seul jour se dilue dans un bloc dont le N est sept fois plus gros et peut passer sous le seuil — 2 800 mots qui avaient des pics en journalier n'en ont plus en hebdomadaire. Les trois grilles ne voient pas exactement la même population d'événements ; c'est un choix d'instrument, pas un défaut.

Limites connues et suite

Deux points notés pour plus tard : écrire la surprise en pleine précision dans les CSV — elle est arrondie à 2 décimales, ce qui explique 45 des 46 écarts de la contre-vérification du NMS ; et une piste de V3 discutée avec Benoît, remplir les fenêtres de **résidus standardisés** sous la loi ajustée plutôt que de fréquences brutes, ce qui éliminerait la sensibilité à N_t par construction.

La suite du travail : les statistiques du CSV des pics (co-sauts par jour, amplitudes, pics par mot) ; comparer avec la variante « vocabulaire $\geq 1\,000$ jours actifs » (39 316 mots) ; puis l'objectif réel, refaire la chaîne sur les autres journaux et comparer les fenêtres *par journal* autour des mêmes pics — c'est là que la question des rachats se joue.

Figures calculées à la compilation depuis `campagne_pca/data/cache_pca/{lemonde, lemonde3j, lemonde7j}.npz`.
Méthode complète et campagne d'hyperparamètres : `campagne_pca/rapport_pdf/rapport.pdf`.