

PCA jointe par triplets — Le Monde, Le Figaro, Ouest-France

Fenêtres des trois médias concaténées autour d'une date commune — configurations journalière (± 20 j) et blocs de 3 j (± 15)

Jusqu'ici, la PCA des sauts traitait chaque média séparément : une fenêtre autour d'un pic donnait un vecteur, et les composantes décrivaient les formes de saut propres à un journal. Ce rapport présente la **PCA jointe** : pour un même événement, on extrait la même fenêtre calendaire dans **trois médias** — *Le Monde*, *Le Figaro* et *Ouest-France* — et on concatène les trois segments en un seul vecteur avant la PCA. Les composantes décrivent alors la réaction *conjointe* des trois journaux : formes partagées, mais aussi décalages et divergences qu'aucune PCA séparée ne peut voir. Chaque composante est relue en deux temps : redécoupée en trois segments superposés (un par média), puis moyennée (forme commune). *Ouest-France* remplace *Les Échos* du trio initial : c'est un quotidien 7 j/7, ce qui évite d'interpoler les week-ends.

La construction des triplets est la suivante. Les pics sont détectés par média comme d'habitude (loi BNB en double fit, seuil de surprise 3). Pour chaque mot, les pics des trois médias sont mis en commun et parcourus par surprise décroissante : le plus fort devient la **référence** (surprise ≥ 4) et fixe la **date commune**, à condition que chacun des deux autres médias ait un pic — le **suiveur**, surprise ≥ 3 — à moins de **7 jours calendaires**. Un triplet retenu supprime les pics voisins à moins d'une largeur de fenêtre dans les trois médias (même logique gloutonne que le NMS, appliquée inter-médias) : les fenêtres d'un mot ne se recouvrent jamais. Les fenêtres sont extraites sur une **grille calendaire ancrée sur la date commune** — le bloc central est centré dessus, les trois segments sont donc strictement synchrones ; les blocs quasi vides ($N < 10$ % de la médiane journalière du média) sont interpolés linéairement, et une fenêtre est écartée si un bloc central manque ou si un segment dépasse 50 % de blocs interpolés. Chaque segment est enfin z-score sur lui-même, pour qu'aucun média n'écrase les autres dans la PCA.

L'étude procède en trois cycles : les résultats de base d'abord, puis la robustesse aux paramètres (tolérance, grille), enfin deux variantes de construction (centrage symétrique, suiveurs stricts) motivées par l'interprétation des cycles précédents.

Corpus et appariement

La période commune aux trois séries va de décembre 2004 à mars 2024, et le vocabulaire commun aux trois tops-10 000 compte **7 035 mots**. L'exigence du triple pic est très sélective : moins de 1 % des pics d'entrée survivent à l'appariement.

	Journalier ± 20 j	Blocs de 3 j ± 15
Pics utilisables — Le Monde	120 250	46 425
Pics utilisables — Le Figaro	112 180	52 249
Pics utilisables — Ouest-France	167 981	79 129
Triplets appariés	3 672	2 080
Gardés par les filtres	3 358	1 930
dont référence ≥ 5	2 776	1 688
dont référence ≥ 6	2 211	1 390
Mots distincts	1 649	1 176
Concentration (seuil 6)	0,13	0,11

Trois observations sur l'appariement. D'abord, *Ouest-France* fournit la référence de 46 % des triplets journaliers (1 542, contre 963 au *Figaro* et 853 au *Monde*). Ce n'est pas une question d'antériorité mais de **débit** : son corpus quotidien est le plus gros des trois (219 000 tokens médians par jour, contre 86 000 au *Monde*), donc à événement égal la surprise statistique y est plus élevée. Ensuite, les décalages des suiveurs montrent qui est en avance : médiane à 0 partout — la synchronisation au jour près domine —, mais *Le Figaro* est le plus précoce (35 % d'avance stricte contre 28 % de retard en journalier ; médiane à -1 jour en blocs de 3 j), tandis que *Le Monde* et *Ouest-France* penchent vers le retard. Le cas du *Monde* s'explique au moins en partie par sa datation d'édition au lendemain. Enfin, les filtres écartent peu de fenêtres (314 en journalier, 150 en 3 j), essentiellement les années creuses d'*Ouest-France* (2005-2008), où les blocs quasi vides sont nombreux.




Figure 1. – Décalage du pic de chaque média par rapport à la date commune, quand il n'est pas la référence (configuration journalière, 2 505 / 2 395 / 1 816 suiveurs).

La **synchronie** entre journaux se mesure directement sur les fenêtres : pour chaque triplet, on corrèle les segments z-scorés deux à deux. Les médianes dessinent une hiérarchie stable aux deux grilles : *Le Monde-Le Figaro* sont les plus proches (0,62 en journalier, 0,82 en 3 j), *Le Figaro-Ouest-France* suivent (0,58 et 0,78), *Le Monde-Ouest-France* ferment la marche (0,53 et 0,74). Les deux nationaux se ressemblent plus entre eux qu'aucun ne ressemble au régional — et tout le monde se ressemble beaucoup plus au grain de 3 jours, signe que l'essentiel du désaccord tient dans un décalage de un à deux jours.

Configuration journalière (± 20 jours)

La PCA tourne sur les 2 211 vecteurs de 123 valeurs (3×41) à référence ≥ 6 ; au seuil 4, les composantes sont les mêmes à l'ordre près et la variance varie de moins d'un point. La concentration (0,13) est nettement meilleure que celle des PCA par média au même grain : la redondance des trois segments structure davantage les fenêtres.




Figure 2. – Les six premières composantes de la PCA jointe journalière (référence ≥ 6), redécoupées en trois segments – un par média.

Les quatre premières composantes sont des **formes communes** : la corrélation moyenne entre leurs trois segments vaut 0,97, 0,94, 0,98 et 0,88. On y retrouve le catalogue des campagnes par média – montée progressive puis chute après le pic (PC1), creux la veille puis niveau durablement plus haut (PC2), pic confiné au jour du saut (PC3), creux encadrants avec pic central (PC4) – mais répété à l’identique par les trois journaux, ce qui confirme que ces formes sont des propriétés de l’événement, pas d’un titre.

La **composante 5 est d’une autre nature** : la corrélation entre ses segments tombe à $-0,11$. Au jour J, le segment d’*Ouest-France* plonge quand ceux du *Monde* et du *Figaro* montent – un axe de divergence entre presse nationale et presse régionale, invisible par construction dans une PCA par média, qui pèse 3,8 % de la variance. Le cycle 2 examine ce que recouvre réellement cet axe.




Figure 3. – Les mêmes six composantes, moyennées sur les trois segments (forme commune).

Les mots qui projettent le plus haut sur ces axes sont les grands événements nationaux : les soirs d’élection pour la composante 3 (« législatives » en juin 2012 et 2017, « municipale » en mars 2008), l’automne 2010 des retraites pour la composante 1 (« retraites », « réforme »), le confinement de mars 2020 pour la composante 2 (« personnels », « partiel »).

Configuration en blocs de 3 jours (± 15 blocs)




Figure 4. – Les six premières composantes de la PCA jointe en blocs de 3 jours (référence ≥ 6), un segment par média.

Au grain de 3 jours, **la divergence disparaît** : les six premières composantes sont toutes des formes communes (corrélations entre segments de 0,81 à 0,99), et il faut descendre à la composante 10 (1,6 % de variance) pour trouver un axe de contraste entre médias. Le catalogue est celui des campagnes précédentes — changement de niveau avant/après (PC1), montée progressive puis chute brutale (PC2), régime haut qui se referme sur le pic (PC3), pic isolé du bloc central (PC4), creux encadrants (PC5), oscillation rapide (PC6) — porté ici par 1 390 fenêtres à référence ≥ 6 , avec une concentration de 0,11.




Figure 5. – Les mêmes six composantes, moyennées sur les trois segments (forme commune).

La comparaison des deux grilles résume le résultat central de ce premier cycle : les trois journaux réagissent aux mêmes événements avec **les mêmes formes**, et leurs désaccords tiennent presque entièrement dans **un décalage de un à deux jours** — visible au grain journalier (composante 5, corrélations médianes autour de 0,55), gommé dès qu'on agrège par blocs de 3 jours (corrélations autour de 0,78, plus aucune composante de contraste dans les dix premières).

Paramètres de ce premier cycle : tolérance d'appariement 7 jours calendaires, référence ≥ 4 à la construction (analyses présentées à ≥ 6 : 2 211 et 1 390 fenêtres, effectifs suffisants sans descendre le seuil), suiveurs ≥ 3 , grille calendaire ancrée, interpolation plafonnée à 50 % par segment.

Cycle 2 — robustesse : tolérance et grille

Deux vérifications s'imposaient : la sensibilité à la **tolérance** d'appariement (rejouée à 3 et 14 jours) et le contrôle en **grille de parution** (l'option historique, où chaque média est lu sur ses propres jours de parution), pour s'assurer que le passage au calendrier ancré ne fabrique pas les résultats. Les composantes de chaque variante sont appariées à celles du cycle 1 par le cosinus des vecteurs de 123 valeurs.

	Fenêtres ≥ 6	K50	Cos. min PC1-6	Axe réf. max
tolérance 7 j (réf.)	2 211	0,13	—	0,61
tolérance 3 j	1 991	0,12	0,89	0,58
tolérance 14 j	2 461	0,14	0,80	0,57
grille parution	2 168	0,13	1,00	0,61

Le verdict est net sur les trois fronts. **Tolérance** : les triplets sont emboîtés (98 % de ceux construits à 3 jours se retrouvent à 7 jours, 97 % de ceux à 7 jours se retrouvent à 14) et les six premières composantes se correspondent une à une (cosinus 0,87 à 0,98 pour 3 jours, 0,71 à 0,98 pour 14) ; les effectifs bougent de ± 15 %, la concentration de $\pm 0,01$. **Grille** : en parution, les correspondances sont parfaites (cosinus 1,00 sur les sept premières composantes, en journalier comme en 3 j) — le calendrier ancré ne fabrique rien, il ne fait que synchroniser proprement les segments.

Ce que recouvre la composante 5. La colonne « axe référence » mesure, pour chaque variante, la corrélation maximale entre une projection et l'identité du média de référence : elle vaut 0,57 à 0,61 dans toutes les variantes, toujours portée par la composante correspondant à la PC5 du cycle 1, quand aucune autre composante ne dépasse 0,28. Ses archétypes le confirment : ses 100 plus fortes projections positives sont toutes des triplets à référence nationale, ses 100 plus fortes négatives sont à 97 % des triplets à référence *Ouest-France* — et les mots sont ordinaires (« cadeau », « sondage », « séries »), pas de grands événements. Cette composante n'est donc pas une opposition éditoriale : c'est un axe qui dit **quel média porte le pic le plus fort**, en partie mécanique puisque la date commune est précisément celle du pic le plus fort. Robuste, mais à ne pas surinterpréter — d'où le cycle 3 : recentrer les fenêtres sur la **médiane des trois dates de pic**, une règle qui ne privilégie aucun média, pour voir si un axe de divergence substantiel subsiste une fois l'asymétrie de construction retirée.

Cycle 3 — centre symétrique et suiveurs stricts

Trois variantes construites en conséquence : les deux configurations recentrées sur la **médiane des trois dates de pic** (3 339 et 1 931 triplets gardés — mêmes appariements qu'au cycle 1, seul le centrage change), et la configuration journalière avec **suiveurs ≥ 4** au lieu de 3 (1 427 triplets, dont 1 216 à référence ≥ 6 : l'exigence double ne divise les effectifs que par 2,3, et il reste largement de quoi faire tourner la PCA — inutile, a fortiori, de descendre le seuil sous 3).

Le centre symétrique tranche la question du cycle 2. Avec la médiane, la corrélation maximale entre une projection et l'identité du média de référence tombe de 0,61 à **0,20** en journalier (0,21 en 3 j) : l'axe « qui porte le pic le plus fort » était bien un artefact du centrage. Les formes communes, elles, traversent le recentrage sans broncher — les quatre premières composantes se retrouvent à cosinus 0,85-0,99, les premières et deuxième échangeant seulement leur rang.

Mais la **direction de divergence survit** : une composante à segments anti-corrélés (similarité $-0,16$) persiste au cinquième rang (3,6 % de variance, cosinus 0,92 avec la PC5 du cycle 1), et le recentrage permet enfin de la lire. Sa projection n'est corrélée ni au déséquilibre de surprise entre titres (0,02), ni à l'identité de la référence : elle l'est à l'**ampleur du décalage temporel** — $+0,45$ avec le décalage absolu d'*Ouest-France*, $-0,29$ avec celui du *Monde*. C'est un axe de **désynchronisation** : il sépare les événements où *Ouest-France* est à contretemps des nationaux de ceux où c'est *Le Monde* qui l'est. La divergence entre médias que la PCA jointe met au jour est donc temporelle, pas formelle — en cohérence avec tout le reste de l'étude.

Le contrôle **suiveurs ≥ 4** ne change rien : composantes appariées une à une (cosinus 0,85 à 0,98), concentration légèrement meilleure (0,10), même axe au cinquième rang. Le seuil suiveur à 3 du cycle 1 n'introduisait donc aucun biais de composition.

Ce qu'il faut retenir

Trois cycles, un tableau cohérent. **Les formes de saut sont des propriétés des événements, pas des journaux** : les quatre premières composantes de chaque configuration sont répétées presque à l'identique par les trois titres (corrélations entre segments de 0,88 à 0,99), reprennent le catalogue des campagnes par média, et résistent à toutes les variantes essayées — tolérance de 3 à 14 jours, grille calendaire ou de parution, centrage sur la référence ou sur la médiane, suiveurs à 3 ou 4. **Ce qui distingue les journaux est temporel** : un décalage de un à deux jours (le *Figaro* le plus souvent en avance, *Le Monde* et *Ouest-France* en retard), visible au grain journalier et gommé dès les blocs de 3 jours, et un axe de désynchronisation qui isole les événements où un titre est à contretemps des deux autres. La PCA jointe tient sa promesse : elle retrouve les formes connues *et* met au jour la structure inter-médias — à condition, comme l'a montré le cycle 3, de neutraliser l'asymétrie de construction avant d'interpréter les axes de divergence.