

PCA multiple V2 (Monde, Figaro, Ouest-France)

Fenêtres concaténées autour des pics du corpus unifié

Ce document reprend l'analyse factorielle multiple des sauts sur *Le Monde*, *Le Figaro* et *Ouest-France* avec un protocole différent du premier rapport. Les dates ne sont plus obtenues en appariant les pics des trois journaux : elles viennent des **pics du corpus unifié** (les 36 médias réunis, vocabulaire des 10 000 mots du *Monde*, période de janvier 2008 à mars 2024), détectés par la loi BNB et filtrés par NMS. Pour chaque pic unifié de surprise supérieure ou égale à 6, la même fenêtre est extraite dans chacun des trois journaux autour de cette date, que le journal ait ou non un pic à lui ; les trois segments sont z-scorés séparément puis concaténés, et la PCA tourne sur ces vecteurs. Deux grilles sont présentées : journalière (± 20 jours) et en blocs de 3 jours (± 15 blocs).

Corpus et fenêtres

Le vocabulaire commun aux trois journaux compte 7 035 mots. Une seconde passe de NMS à la largeur de la fenêtre garantit que deux fenêtres d'un même mot ne se recouvrent jamais, et une fenêtre est écartée si son bloc central est vide dans un des journaux, si un segment dépasse 50 % de blocs interpolés, ou si un segment est plat (le mot n'y apparaît pas : 11 cas en journalier, 2 en blocs de 3 jours). Pour chaque fenêtre on note l'**écho** de chaque journal : un pic qui lui est propre, de surprise supérieure ou égale à 3, à moins de 7 jours de la date unifiée.

	Journalier (± 20 j)	Blocs de 3 j (± 15)
Pics unifiés gardés par le NMS (≥ 6)	33 239	16 390
Fenêtres retenues	17 036	8 414
Écho Le Monde (%)	40	41
Écho Le Figaro (%)	49	53
Écho Ouest-France (%)	46	52
Aucun écho (%)	22	18
Écho dans les trois (%)	16	18
Variance de la composante 1 (%)	5,4	7,1
Concentration K50	0,28	0,24

Un peu plus de la moitié des pics unifiés donnent une fenêtre exploitable dans les trois journaux. Dans un cas sur cinq, aucun des trois titres n'a de pic propre autour de la date : l'événement est porté par d'autres médias. Les trois échos ne sont réunis que dans 16 à 18 % des fenêtres, ce qui correspond à l'ancien corpus de triplets — 84 % des triplets journaliers du premier rapport se retrouvent parmi les fenêtres V2.

Configuration journalière (± 20 jours)




Figure 1. – Les six premières composantes journalières (surprise unifiée ≥ 6), un segment par média.

Le spectre est plus étalé que dans l'analyse par triplets (K50 de 0,28 contre 0,14) : les fenêtres où un journal reste muet ajoutent du bruit sans structure. La **composante 1** est un pic confiné au jour du saut, identique dans les trois journaux (corrélation entre segments 0,99), et son score suit le nombre de journaux qui font écho (corrélation 0,53) : c'est un axe d'intensité de la couverture, absent par construction de l'analyse par triplets. La **composante 2** oppose le jour du saut chez *Ouest-France* à la veille chez les deux nationaux : l'axe de désynchronisation identifié en cinquième position dans le premier rapport passe ici au second rang, et son score est corrélé à $-0,53$ à l'écho d'*Ouest-France* — il sépare d'abord les événements que le régional reprend de ceux qu'il ignore. Les composantes 3 (changement de niveau bas avant, haut après), 4 (pic la veille) et 6 (montée puis creux) sont des formes communes ; la **composante 5** oppose *Le Monde* au jour du saut (corrélation entre segments 0,03 ; le score dépend de l'écho du *Figaro*, corrélation 0,30 en valeur absolue, pas de celui du *Monde*, 0,11). Plus loin, la composante 7 est une oscillation de période 7 jours partagée par les trois titres.

Configuration en blocs de 3 jours (± 15 blocs)




Figure 2. – Les six premières composantes en blocs de 3 jours (surprise unifiée ≥ 6), un segment par média.

Le catalogue est celui du grain journalier, sans le décalage d'un jour : pic au bloc du saut (composante 1, corrélation 0,96, score corrélié à 0,54 au nombre d'échos), changement de niveau (composante 2, 0,94), montée progressive puis pic et retombée (composante 3, 0,72, pic plus marqué chez *Ouest-France* et score corrélié à 0,46 à son écho), creux puis pic (composante 5, 0,90). La **composante 4** est propre à *Ouest-France* : un pic au bloc du saut alors que les deux nationaux restent plats, score corrélié à +0,38 à l'écho d'*Ouest-France* et à -0,24 à celui du *Figaro* — l'axe des événements que le régional reprend sans les nationaux.

Le corpus de triplets comme sous-ensemble

Les fenêtres V2 se laissent stratifier par le nombre de journaux qui font écho. Pour chaque strate, la PCA est refaite sur ses seules fenêtres et ses six premières composantes sont reprojétées sur les six premières de l'analyse par triplets du premier rapport (même seuil, centrage médiane) ; le recouvrement minimal mesure la part de norme conservée par la composante la moins bien retrouvée.

	n (j)	K50 (j)	Rec. (j)	n (3 j)	K50 (3 j)	Rec. (3 j)
Toutes les fenêtres	17 036	0,28	0,75	8 414	0,24	0,61
Écho dans les trois	2 674	0,15	0,85	1 532	0,12	0,69
Au moins deux échos	7 096	0,20	0,52	3 827	0,17	0,72
Aucun écho	3 701	0,35	0,75	1 481	0,31	0,42

Restreinte aux fenêtres où les trois journaux font écho, la PCA V2 retrouve le sous-espace de l'analyse par triplets (recouvrement minimal 0,85 en journalier, 0,69 en blocs de 3 jours) et sa concentration (0,15 et 0,12). À l'autre bout, les fenêtres sans aucun écho ont un spectre presque plat (K50 de 0,35 et 0,31) : elles pèsent un cinquième du corpus et sont responsables de l'étalement du spectre global. Le protocole V2 contient donc l'ancien comme cas particulier, et lui ajoute deux axes que l'exigence du triple accord rendait invisibles : l'intensité de la couverture (composante 1) et la couverture par un seul titre (composante 4 en blocs de 3 jours).