

Quels mots vont ensemble, dans Le Figaro ?

Depuis 600 mots fréquents (2005-2024), les groupes qui se dégagent naturellement

Comment lire ce document

6 586 jours du *Figaro*, entre 2005 et 2024. Pour chacun des 600 mots les plus fréquents du journal (hors mots outils), on a une courbe : combien de fois ce mot apparaît chaque jour, une fois corrigé de l'épaisseur du journal ce jour-là. Deux mots dont les courbes montent et descendent **ensemble** sortent du lot les mêmes jours — un thème partagé. En comparant ces 600 courbes deux à deux, un algorithme fait ressortir 22 groupes nettement soudés ; les onze plus faciles à nommer sont représentés ci-dessous, cinq mots chacun.

Les groupes de mots



Figure 1. – Onze thèmes qui émergent des 600 mots les plus fréquents du Figaro (2005-2024), sans qu'aucun thème n'ait été indiqué à l'avance à l'algorithme. Dans chaque groupe, un trait relie chaque mot à celui de son groupe avec lequel il apparaît le plus souvent le même jour. Les traits noirs épais relient deux groupes entre eux, avec la force du lien.

Chaque bulle est un mot, chaque couleur un thème : « justice », « tribunal », « judiciaire », « procès » et « prison » se regroupent tout seuls parce qu'ils apparaissent statistiquement les mêmes jours. La marque du journal est ici le **sport** : le plus gros groupe repéré par l'algorithme rassemble à lui seul 123 mots des 600, autour du résultat sportif (« match », « défaite », « score », « championnat », et les noms des clubs français). Il est aussi le plus soudé de tous les groupes montrés.

Les trois liens entre thèmes les plus forts se lisent sans difficulté : **Sport** ↔ **Bleus**, le sport de club et l'équipe nationale ; puis deux liens autour de la chronique financière, **Marchés** ↔ **Euro** et **Marchés** ↔ **États-Unis** — les jours de marché sont les jours où l'on parle de la dette et de Wall Street.

Trois réserves : seuls 55 des 600 mots sont représentés, les liens montrés sont les plus forts et non les seuls, et une corrélation ne dit rien de la causalité.

Combien de thèmes sont statistiquement solides ?

Même 600 mots sans aucun lien réel afficheraient, sur un nombre fini de jours, des corrélations non nulles. La loi de Marchenko-Pastur décrit la forme de ce bruit : au-delà de son bord droit, une structure commune est défendable ; en-deçà, le hasard suffit.

Prise telle quelle, cette loi suppose 600 courbes indépendantes mesurées sur 6 586 jours indépendants. Ni l'un ni l'autre n'est vrai : un mot reste dans l'actualité plusieurs jours d'affilée, et les journées se ressemblent. On ne lui impose donc pas ses paramètres, on les **ajuste** sur l'histogramme observé : la loi a deux réglages, sa largeur et son échelle, et on cherche le couple qui colle le mieux au bulk.




Figure 2. – Les 600 valeurs propres de la matrice de corrélation, en échelle logarithmique (sans quoi les valeurs de droite, peu nombreuses, seraient invisibles face au bulk). En gris pointillé, la loi de Marchenko-Pastur avec ses paramètres théoriques : elle ne commence qu'à 0,49, alors que 216 valeurs propres observées sont plus basses, et passe au-dessus de l'histogramme sur toute sa moitié droite. En bleu foncé, la même loi ajustée sur l'histogramme : elle épouse le bulk, et c'est son bord droit qui sert de seuil. À droite du seuil, des valeurs qu'aucun hasard d'échantillonnage ne peut produire.


L'ajustement est instructif à lui seul. Il ramène le nombre de jours réellement indépendants à 2 569 au lieu de 6 586 : les journées d'un quotidien se répètent, et l'information apportée par vingt-cinq ans d'archives vaut moins que ce que le calendrier laisse croire. Le seuil descend en conséquence à 1,41, contre 1,69 pour la loi non ajustée.

Une fois la loi calée, le partage est net : 543 valeurs propres sont indiscernables du hasard, 57 en sortent — contre 42 avec la loi non ajustée, qui sous-estime le signal parce qu'elle place son bord trop à droite. C'est un décompte de directions distinctes du bruit, pas de thèmes nommables.


Que contiennent les directions retenues ?

Chaque direction retenue est décrite par le poids qu'elle donne à chacun des 600 mots. Ces poids sont positifs ou négatifs : une direction **oppose** deux registres de vocabulaire, les jours où le premier domine étant les jours où le second est absent.


1. Actualité générale / pages sport




2. Années 2000-2010 / années 2020




3. Crise sanitaire / figures des 2000



4. Politique intérieure / marchés



5. Faits divers / vie économique



6. Diplomatie / sport et célébrités




Figure 3. – Les six premières directions retenues, avec les mots qui les portent le plus. À droite les mots de poids positif, à gauche ceux de poids négatif. Ce sont des axes d'actualité concurrente — les jours d'un pôle ne sont pas les jours de l'autre.

La direction la plus puissante — et de loin, sa valeur propre vaut près du double de la suivante — oppose tout le reste du journal à ses **pages sport**. Le sport n'est pas seulement le plus gros groupe de mots du *Figaro*, c'est sa première ligne de partage : les jours de forte actualité sportive sont des jours où le vocabulaire du reste du journal recule.

Vient ensuite une opposition d'**époques** (années 2000-2010 contre années 2020, « obama » et « internet » face à « covid » et « emmanuel »), puis des axes thématiques : la crise sanitaire contre les figures politiques des années 2000, la politique intérieure contre les marchés, les faits divers contre la vie économique et sociale, la diplomatie contre le sport et les célébrités. C'est exactement ce qu'il faudra surveiller après un rachat : un axe qui se déforme signale un déplacement de la couverture, pas seulement l'apparition d'un mot nouveau.

Nettoyer la matrice

Les 543 valeurs propres du bulk — celles que la loi ajustée englobe — ne portent aucune information fiable. On les remplace par leur moyenne, en gardant intactes les 57 autres, puis on reconstruit la matrice.




Figure 4. – Chaque point est une paire de mots : sa corrélation avant nettoyage (horizontale) et après (verticale). La diagonale marque l'absence de changement. Les liens forts, à droite, sont ramenés vers le bas — c'est là que le bruit d'échantillonnage gonflait le plus les valeurs.

Le nuage reste serré autour de la diagonale : le nettoyage ne bouleverse pas la matrice. Les liens faibles ne bougent quasiment pas, les plus forts sont tirés vers le bas — une corrélation forte mesurée sur un échantillon fini est presque toujours un peu surestimée.

Le nombre de groupes bouge peu (23 contre 22), mais ce chiffre stable masque une recomposition réelle : 5,2 % des paires de mots changent de statut. Le débruitage ne change pas le nombre de boîtes, il change leur contenu. Et le résultat ne dépend pas de la valeur exacte du seuil : en gardant 42 valeurs propres au lieu de 57, on trouve 23 groupes ; avec 72, 21 ; contre 23 au seuil exact.

Cela comptera pour la suite : découpé en fenêtres avant/après rachat, chaque période comptera un millier de jours au lieu de 6 586 : le rapport ajusté montera bien au-dessus de 0,23 et les matrices seront beaucoup plus bruitées qu'ici. Raison de plus pour réajuster la loi sur chaque fenêtre plutôt que de lui faire confiance sur parole.