

Quels mots vont ensemble, dans Le Monde ?

Depuis 600 mots fréquents (2000-2025), les groupes qui se dégagent naturellement

Comment lire ce document

9 477 jours du *Monde*, entre 2000 et 2025. Pour chacun des 600 mots les plus fréquents du journal (hors mots outils comme « le », « de », « pour »), on a une courbe : combien de fois ce mot apparaît chaque jour, une fois corrigé de l'épaisseur du journal ce jour-là. Deux mots dont les courbes montent et descendent **ensemble** sont « corrélés » : ils sortent le lot les mêmes jours, ce qui trahit un thème partagé.

En comparant ces 600 courbes deux à deux, un algorithme fait ressortir 27 groupes de mots nettement soudés entre eux. Onze d'entre eux, faciles à nommer et à comprendre d'un coup d'œil, sont représentés ci-dessous — cinq mots par groupe, les plus représentatifs.

Les groupes de mots




Figure 1. – Onze thèmes qui émergent naturellement des 600 mots les plus fréquents du Monde (2000-2025), sans qu'aucun thème n'ait été indiqué à l'avance à l'algorithme. Dans chaque groupe, un trait relie chaque mot à celui de son groupe avec lequel il apparaît le plus souvent le même jour. Les traits noirs épais relient deux groupes entre eux, avec la force du lien.

Chaque bulle est un mot, chaque couleur un thème. Un mot est relié à celui de son groupe avec lequel il sort le plus souvent le même jour — c'est ce qui dessine visuellement le thème, sans qu'on ait eu besoin de le décider

à l'avance : « justice », « tribunal », « judiciaire », « cour » et « procès » se regroupent tout seuls parce qu'ils apparaissent statistiquement les mêmes jours dans le journal.

Trois liens entre thèmes, plus forts que tous les autres, sont mis en évidence en noir :

- **Emploi ↔ Finance** — le lien le plus fort du graphe. Un article qui parle de croissance économique mentionne aussi, le même jour, les marchés et le crédit : ces deux thèmes ne font presque qu'un dans la presse.
- **Défense ↔ États-Unis** — les jours où *Le Monde* parle de l'armée et de la sécurité sont aussi, très souvent, des jours où il est question de Washington.
- **Élections ↔ Personnalités** — les campagnes électorales se lisent à travers les hommes politiques qui les incarnent.

Ce que cette image ne montre pas

- **Seuls 55 des 600 mots sont représentés.** Les onze groupes montrés sont les plus nets ; d'autres existent (sport amateur, culture, environnement...) mais ont été laissés de côté pour garder le graphe lisible.
- **Les liens choisis sont les plus forts, pas les seuls.** Beaucoup d'autres liens, plus faibles, existent entre les mots et les thèmes — ce document montre la structure la plus nette, pas la totalité de l'information.
- **Corrélation ne veut pas dire causalité.** Que « emploi » et « finance » sortent souvent le même jour ne dit rien sur qui influence qui, seulement qu'ils font l'actualité ensemble.

Combien de thèmes sont statistiquement solides ?

Le graphe ci-dessus est construit à la main : on choisit onze groupes parce qu'ils se lisent bien, pas parce qu'un calcul a dit « il y en a onze ». Une question plus rigoureuse se pose : sur 9 477 jours de journal seulement, combien de thèmes réellement distincts peut-on espérer démêler parmi 600 mots, avant de commencer à confondre du vrai signal avec du simple hasard d'échantillonnage ?

Même 600 mots **sans aucun lien réel entre eux** afficheraient des corrélations non nulles, mesurées sur un nombre fini de jours — comme deux séries de pile-ou-face peuvent sembler liées sur un tirage court. La loi de Marchenko-Pastur décrit la forme de ce bruit : au-delà de son bord droit, une structure commune est défendable ; en-deçà, le hasard suffit à l'expliquer.

Encore faut-il la régler correctement. Prise avec ses paramètres théoriques, elle suppose 600 courbes indépendantes mesurées sur 9 477 jours indépendants ; or un mot reste dans l'actualité plusieurs jours d'affilée, et les journées d'un quotidien se ressemblent. On ne lui impose donc pas ses paramètres, on les **ajuste** sur l'histogramme observé : la loi a deux réglages, sa largeur et son échelle, et on cherche par moindres carrés le couple qui colle le mieux au bulk — en écartant à chaque passe les valeurs propres qui en dépassent.




Figure 2. – Les 600 valeurs propres de la matrice de corrélation, en échelle logarithmique (sans quoi les quelques dizaines de valeurs de droite seraient invisibles face au bulk). En gris pointillé, la loi de Marchenko-Pastur avec ses paramètres théoriques : elle ne commence qu'à 0,56, alors que 216 valeurs propres observées sont plus basses, et passe au-dessus de l'histogramme sur toute sa moitié droite. En bleu foncé, la même loi ajustée sur l'histogramme : elle épouse le bulk, et c'est son bord droit qui sert de seuil. À droite du seuil, des valeurs qu'aucun hasard d'échantillonnage ne peut produire.


L'ajustement est instructif à lui seul. Il ramène le nombre de jours réellement indépendants à 3 465 au lieu de 9 477 : l'information apportée par vingt-cinq ans d'archives vaut moins que ce que le calendrier laisse croire. Le seuil descend en conséquence à 1.37, contre 1.57 pour la loi non ajustée.

Une fois la loi calée, le partage est net : 533 valeurs propres sont bien indiscernables du hasard, 67 en sortent – contre 52 avec la loi non ajustée, qui sous-estime le signal parce qu'elle place son bord trop à droite.


Que contiennent les valeurs propres retenues ?

Une valeur propre est une direction dans les données, décrite par le poids qu'elle donne à chacun des 600 mots. Ces poids sont positifs ou négatifs, et c'est là que la lecture devient concrète : chaque direction oppose deux registres de vocabulaire, qui s'excluent dans le journal. Un poids fortement positif d'un côté, fortement négatif de l'autre, signifie que les jours où le premier groupe de mots domine sont les jours où le second est absent.


1. Économie / actualité des années 2020




2. Société et santé / figures des années 2000




3. Guerre américaine / politique intérieure



4. Défense et diplomatie / culture



5. Crise de l'euro / vie politique française



6. Affaires judiciaires / gestion locale




Figure 3. – Les six premières directions retenues, avec les mots qui les portent le plus. Chaque direction oppose deux registres : à droite les mots de poids positif, à gauche ceux de poids négatif. Ce sont des axes d'actualité concurrente — les jours d'un pôle ne sont pas les jours de l'autre.

Deux types d'axes apparaissent. Les deux premiers, les plus puissants, opposent en réalité des **époques** : « croissance » et « marché » d'un côté, « covid », « trump » et « emmanuel » de l'autre ; puis « santé » et « réseaux » face à « chirac », « jacques » et « jean ». Sur vingt-cinq ans, la première ligne de partage du journal est chronologique — le vocabulaire des années 2000 n'est pas celui des années 2020.

Les suivants sont thématiques. Le troisième oppose la guerre et les États-Unis à la politique intérieure française : deux sujets qui se disputent la une, rarement dominants le même jour. Le quatrième sépare défense et diplomatie des pages culture, le cinquième isole la crise de l'euro, le sixième les affaires judiciaires. Plus loin dans le classement viennent des axes plus fins mais tout aussi identifiables : le sport, la Russie, ou une direction portée par « donald », « trump » et « syrie ».

Ces directions ne sont donc pas des abstractions mathématiques : ce sont les grandes lignes de partage de l'actualité, retrouvées sans qu'aucune liste de thèmes n'ait été fournie à l'algorithme. Elles apportent aussi une information que le graphe d'ouverture ne donne pas : non seulement quels mots vont ensemble, mais quels registres s'excluent. C'est exactement ce qu'il faudra surveiller après un rachat — un axe qui se déforme signale un déplacement de la couverture, pas seulement l'apparition d'un mot nouveau.

Attention toutefois à ce que le chiffre de 67 signifie. Marchenko-Pastur ne compte pas des thèmes : il dit lesquelles de ces directions se distinguent du bruit, pas lesquelles sont nommables ou intéressantes. Les 67 directions ne sont donc pas 67 faux positifs face aux onze thèmes du graphe — les nommer relève de l'interprétation, pas de la significativité. De même, le rapport mots/jours n'est pas un curseur à régler : plus on accumule de jours, plus le seuil descend vers 1 et plus on distingue de structures fines. C'est l'effet recherché, pas une faiblesse. Noter simplement que le rapport qui compte est celui que l'ajustement mesure (0.17 ici) et non celui du calendrier (0.063) : les jours d'un quotidien ne sont pas des tirages indépendants.

L'intérêt de ce seuil pour le mémoire est ailleurs : il permet de nettoyer la matrice, et servira de repère quand on comparera deux périodes avant/après un rachat.

Nettoyer la matrice

Les 533 valeurs propres du bulk — celles que la loi ajustée englobe — ne portent aucune information fiable : leurs écarts ne reflètent que le hasard du tirage. On les remplace donc toutes par leur moyenne, en gardant intactes les 67 autres, puis on reconstruit la matrice à partir de ce spectre corrigé.




Figure 4. — Chaque point est une paire de mots : sa corrélation avant nettoyage (horizontale) et après (verticale). La diagonale marque l'absence de changement. Les liens forts, à droite, sont ramenés vers le bas — c'est là que le bruit d'échantillonnage gonflait le plus les valeurs.

Le nuage reste serré autour de la diagonale : le nettoyage ne bouleverse pas la matrice. Le détail à droite montre où il agit vraiment — les liens faibles ne bougent quasiment pas, tandis que les plus forts (au-delà de 0,4) sont tirés vers le bas. C'est cohérent : une corrélation forte mesurée sur un échantillon fini est presque toujours un peu surestimée, et le nettoyage lui retire cette part de hasard.

Sur le nombre de groupes, l'effet est mince — 25 groupes d'au moins cinq mots contre 27 sur la matrice brute. Mais ce chiffre stable masque une recomposition réelle : 1,0 % des paires de mots changent de statut, c'est-à-dire se retrouvent ensemble après nettoyage alors qu'elles étaient séparées avant, ou l'inverse. Le débruitage ne change pas le nombre de boîtes, il change leur contenu.

C'est pour la suite que cela compte. En découpant en fenêtres avant/après rachat, chaque période comptera de l'ordre de 1 000 jours au lieu de 9 477 : le rapport mots/jours montera vers 0,5 — et le rapport ajusté plus haut encore — et les matrices seront bien plus bruitées qu'ici. Nettoyer deviendra alors nécessaire pour ne pas prendre un artefact d'échantillonnage pour un changement de ligne éditoriale. La loi devra être réajustée sur chaque fenêtre, et non transposée d'une période à l'autre.

Une réserve, enfin : l'ajustement absorbe dans un rapport effectif ce que la dépendance entre jours et la winsorisation des résidus à ± 8 font au spectre, mais il reste un calage empirique sur un histogramme, pas une frontière exacte — d'où l'intérêt de vérifier qu'il n'est pas critique. En gardant 52 valeurs propres au lieu de 67, on trouve 28 groupes ; avec 82, 25 ; contre 25 au seuil exact. Le résultat ne bascule pas sur la valeur précise du seuil.