

Quels mots vont ensemble, dans Le Monde ?

Depuis 600 mots fréquents (2000-2025), les groupes qui se dégagent naturellement

Comment lire ce document

9 477 jours du *Monde*, entre 2000 et 2025. Pour chacun des 600 mots les plus fréquents du journal (hors mots outils comme « le », « de », « pour »), on a une courbe : combien de fois ce mot apparaît chaque jour, une fois corrigé de l'épaisseur du journal ce jour-là. Deux mots dont les courbes montent et descendent **ensemble** sont « corrélés » : ils sortent le lot les mêmes jours, ce qui trahit un thème partagé.

En comparant ces 600 courbes deux à deux, un algorithme fait ressortir 27 groupes de mots nettement soudés entre eux. Onze d'entre eux, faciles à nommer et à comprendre d'un coup d'œil, sont représentés ci-dessous — cinq mots par groupe, les plus représentatifs.

Les groupes de mots




Figure 1. – Onze thèmes qui émergent naturellement des 600 mots les plus fréquents du Monde (2000-2025), sans qu'aucun thème n'ait été indiqué à l'avance à l'algorithme. Dans chaque groupe, un trait relie chaque mot à celui de son groupe avec lequel il apparaît le plus souvent le même jour. Les traits noirs épais relient deux groupes entre eux, avec la force du lien.

Chaque bulle est un mot, chaque couleur un thème. Un mot est relié à celui de son groupe avec lequel il sort le plus souvent le même jour — c'est ce qui dessine visuellement le thème, sans qu'on ait eu besoin de le décider

à l'avance : « justice », « tribunal », « judiciaire », « cour » et « procès » se regroupent tout seuls parce qu'ils apparaissent statistiquement les mêmes jours dans le journal.

Trois liens entre thèmes, plus forts que tous les autres, sont mis en évidence en noir :

- **Emploi ↔ Finance** — le lien le plus fort du graphe. Un article qui parle de croissance économique mentionne aussi, le même jour, les marchés et le crédit : ces deux thèmes ne font presque qu'un dans la presse.
- **Défense ↔ États-Unis** — les jours où *Le Monde* parle de l'armée et de la sécurité sont aussi, très souvent, des jours où il est question de Washington.
- **Élections ↔ Personnalités** — les campagnes électorales se lisent à travers les hommes politiques qui les incarnent.

Ce que cette image ne montre pas

- **Seuls 55 des 600 mots sont représentés.** Les onze groupes montrés sont les plus nets ; d'autres existent (sport amateur, culture, environnement...) mais ont été laissés de côté pour garder le graphe lisible.
- **Les liens choisis sont les plus forts, pas les seuls.** Beaucoup d'autres liens, plus faibles, existent entre les mots et les thèmes — ce document montre la structure la plus nette, pas la totalité de l'information.
- **Corrélation ne veut pas dire causalité.** Que « emploi » et « finance » sortent souvent le même jour ne dit rien sur qui influence qui, seulement qu'ils font l'actualité ensemble.

Combien de thèmes sont statistiquement solides ?

Le graphe ci-dessus est construit à la main : on choisit onze groupes parce qu'ils se lisent bien, pas parce qu'un calcul a dit « il y en a onze ». Une question plus rigoureuse se pose : sur 9 477 jours de journal seulement, combien de thèmes réellement distincts peut-on espérer démêler parmi 600 mots, avant de commencer à confondre du vrai signal avec du simple hasard d'échantillonnage ?

Même 600 mots **sans aucun lien réel entre eux** afficheraient des corrélations non nulles, mesurées sur un nombre fini de jours — comme deux séries de pile-ou-face peuvent sembler liées sur un tirage court. La loi de Marchenko-Pastur donne la frontière de ce bruit : au-delà, une structure commune est défendable ; en-deçà, le hasard suffit à l'expliquer.




Figure 2. — Les 600 valeurs propres de la matrice de corrélation, en échelle logarithmique (sans quoi les 52 valeurs de droite, très peu nombreuses, seraient invisibles face aux 548 du bulk). La courbe noire est la densité de pur bruit prédite par Marchenko-Pastur : elle épouse le bulk observé. À droite du seuil, 52 valeurs qu'aucun hasard d'échantillonnage ne peut produire.

La courbe théorique épouse le bulk observé : ces 548 valeurs propres sont bien indiscernables du hasard. 52 en sortent, au-delà de 1.57.

Que contiennent les valeurs propres retenues ?

Une valeur propre est une direction dans les données, décrite par le poids qu'elle donne à chacun des 600 mots. Ces poids sont positifs ou négatifs, et c'est là que la lecture devient concrète : chaque direction oppose deux registres de vocabulaire, qui s'excluent dans le journal. Un poids fortement positif d'un côté, fortement négatif de l'autre, signifie que les jours où le premier groupe de mots domine sont les jours où le second est absent.




Figure 3. – Les six premières directions retenues, avec les mots qui les portent le plus. Chaque direction oppose deux registres : à droite les mots de poids positif, à gauche ceux de poids négatif. Ce sont des axes d'actualité concurrente — les jours d'un pôle ne sont pas les jours de l'autre.

Deux types d'axes apparaissent. Les deux premiers, les plus puissants, opposent en réalité des **époques** : « croissance » et « marché » d'un côté, « covid », « trump » et « emmanuel » de l'autre ; puis « santé » et « réseaux » face à « chirac », « jacques » et « jean ». Sur vingt-cinq ans, la première ligne de partage du journal est chronologique — le vocabulaire des années 2000 n'est pas celui des années 2020.

Les suivants sont thématiques. Le troisième oppose la guerre et les États-Unis à la politique intérieure française : deux sujets qui se disputent la une, rarement dominants le même jour. Le quatrième sépare défense et diplomatie des pages culture, le cinquième isole la crise de l'euro, le sixième les affaires judiciaires. Plus loin dans le classement viennent des axes plus fins mais tout aussi identifiables : le sport, la Russie, ou une direction portée par « donald », « trump » et « syrie ».

Ces directions ne sont donc pas des abstractions mathématiques : ce sont les grandes lignes de partage de l'actualité, retrouvées sans qu'aucune liste de thèmes n'ait été fournie à l'algorithme. Elles apportent aussi une information que le graphe d'ouverture ne donne pas : non seulement quels mots vont ensemble, mais quels registres s'excluent. C'est exactement ce qu'il faudra surveiller après un rachat — un axe qui se déforme signale un déplacement de la couverture, pas seulement l'apparition d'un mot nouveau.

Attention toutefois à ce que le chiffre de 52 signifie. Marchenko-Pastur ne compte pas des thèmes : il dit lesquelles de ces directions se distinguent du bruit, pas lesquelles sont nommables ou intéressantes. Les 52 directions ne sont donc pas 52 faux positifs face aux onze thèmes du graphe — les nommer relève de l'interprétation, pas de la significativité. De même, le ratio mots/jours (0.063 ici) n'est pas un curseur à régler : plus on accumule de jours, plus le seuil descend vers 1 et plus on distingue de structures fines. C'est l'effet recherché, pas une faiblesse.

L'intérêt de ce seuil pour le mémoire est ailleurs : il permet de nettoyer la matrice, et servira de repère quand on comparera deux périodes avant/après un rachat.

Nettoyer la matrice

Les 548 valeurs propres du bulk ne portent aucune information fiable : leurs écarts ne reflètent que le hasard du tirage. On les remplace donc toutes par leur moyenne, en gardant intactes les 52 autres, puis on reconstruit la matrice à partir de ce spectre corrigé.




Figure 4. – Chaque point est une paire de mots : sa corrélation avant nettoyage (horizontale) et après (verticale). La diagonale marque l'absence de changement. Les liens forts, à droite, sont ramenés vers le bas — c'est là que le bruit d'échantillonnage gonflait le plus les valeurs.

Le nuage reste serré autour de la diagonale : le nettoyage ne bouleverse pas la matrice. Le détail à droite montre où il agit vraiment — les liens faibles ne bougent quasiment pas, tandis que les plus forts (au-delà de 0,4) sont tirés vers le bas. C'est cohérent : une corrélation forte mesurée sur un échantillon fini est presque toujours un peu surestimée, et le nettoyage lui retire cette part de hasard.

Sur le nombre de groupes, l'effet est mince — 28 groupes d'au moins cinq mots contre 27 sur la matrice brute. Mais ce chiffre stable masque une recomposition réelle : 1,0 % des paires de mots changent de statut, c'est-à-dire se retrouvent ensemble après nettoyage alors qu'elles étaient séparées avant, ou l'inverse. Le débruitage ne change pas le nombre de boîtes, il change leur contenu.

C'est pour la suite que cela compte. En découpant en fenêtres avant/après rachat, chaque période comptera de l'ordre de 1 000 jours au lieu de 9 477 : le ratio mots/jours montera vers 0,5 et les matrices seront bien plus bruitées qu'ici. Nettoyer deviendra alors nécessaire pour ne pas prendre un artefact d'échantillonnage pour un changement de ligne éditoriale.

Une réserve, enfin : le seuil suppose des jours indépendants, alors que l'actualité d'un jour déborde sur le lendemain, et les résidus sont winsorisés à ± 8 . C'est un repère raisonnable, pas une frontière exacte — d'où l'intérêt de vérifier qu'il n'est pas critique. En gardant 45 valeurs propres au lieu de 52, on trouve 27 groupes ; avec 60, 29 ; contre 28 au seuil exact. Le résultat ne bascule pas sur la valeur précise du seuil.