

Quels mots vont ensemble, dans Le Monde ?

Depuis 600 mots fréquents (2000-2025), les groupes qui se dégagent naturellement

Comment lire ce document

9 477 jours du *Monde*, entre 2000 et 2025. Pour chacun des 600 mots les plus fréquents du journal (hors mots outils comme « le », « de », « pour »), on a une courbe : combien de fois ce mot apparaît chaque jour, une fois corrigé de l'épaisseur du journal ce jour-là. Deux mots dont les courbes montent et descendent **ensemble** sont « corrélés » : ils sortent le lot les mêmes jours, ce qui trahit un thème partagé.

En comparant ces 600 courbes deux à deux, un algorithme fait ressortir 27 groupes de mots nettement soudés entre eux. Onze d'entre eux, faciles à nommer et à comprendre d'un coup d'œil, sont représentés ci-dessous — cinq mots par groupe, les plus représentatifs.

Les groupes de mots




Figure 1. – Onze thèmes qui émergent naturellement des 600 mots les plus fréquents du Monde (2000-2025), sans qu’aucun thème n’ait été indiqué à l’avance à l’algorithme. Dans chaque groupe, un trait relie chaque mot à celui de son groupe avec lequel il apparaît le plus souvent le même jour. Les traits noirs épais relient deux groupes entre eux, avec la force du lien.

Chaque bulle est un mot, chaque couleur un thème. Un mot est relié à celui de son groupe avec lequel il sort le plus souvent le même jour — c’est ce qui dessine visuellement le thème, sans qu’on ait eu besoin de le décider à l’avance : « justice », « tribunal », « judiciaire », « cour » et « procès » se regroupent tout seuls parce qu’ils apparaissent statistiquement les mêmes jours dans le journal.

Trois liens entre thèmes, plus forts que tous les autres, sont mis en évidence en noir :

- **Emploi ↔ Finance** — le lien le plus fort du graphe. Un article qui parle de croissance économique mentionne aussi, le même jour, les marchés et le crédit : ces deux thèmes ne font presque qu’un dans la presse.
- **Défense ↔ États-Unis** — les jours où *Le Monde* parle de l’armée et de la sécurité sont aussi, très souvent, des jours où il est question de Washington.
- **Élections ↔ Personnalités** — les campagnes électorales se lisent à travers les hommes politiques qui les incarnent.

Ce que cette image ne montre pas

- **Seuls 55 des 600 mots sont représentés.** Les onze groupes montrés sont les plus nets ; d'autres existent (sport amateur, culture, environnement...) mais ont été laissés de côté pour garder le graphe lisible.
- **Les liens choisis sont les plus forts, pas les seuls.** Beaucoup d'autres liens, plus faibles, existent entre les mots et les thèmes — ce document montre la structure la plus nette, pas la totalité de l'information.
- **Corrélation ne veut pas dire causalité.** Que « emploi » et « finance » sortent souvent le même jour ne dit rien sur qui influence qui, seulement qu'ils font l'actualité ensemble.