

Quels mots vont ensemble, dans Les Échos ?

Depuis 600 mots fréquents (2000-2024), les groupes qui se dégagent naturellement

Comment lire ce document

7 618 jours des *Échos*, entre 2000 et 2024. Pour chacun des 600 mots les plus fréquents du journal (hors mots outils), on a une courbe : combien de fois ce mot apparaît chaque jour, une fois corrigé de l'épaisseur du journal ce jour-là. Deux mots dont les courbes montent et descendent **ensemble** sortent du lot les mêmes jours — un thème partagé. En comparant ces 600 courbes deux à deux, un algorithme fait ressortir 22 groupes nettement soudés ; les onze plus faciles à nommer sont représentés ci-dessous, cinq mots chacun.

Les groupes de mots




Figure 1. – Onze thèmes qui émergent des 600 mots les plus fréquents des *Échos* (2000-2024), sans qu'aucun thème n'ait été indiqué à l'avance à l'algorithme. Dans chaque groupe, un trait relie chaque mot à celui de son groupe avec lequel il apparaît le plus souvent le même jour. Les traits noirs épais relient deux groupes entre eux, avec la force du lien.

Chaque bulle est un mot, chaque couleur un thème : « budgétaire », « déficit », « dépenses », « pib » et « bercy » se regroupent tout seuls parce qu'ils apparaissent statistiquement les mêmes jours. La marque du journal économique est nette — cinq des onze thèmes relèvent de l'économie et de la finance, et le plus gros groupe repéré par l'algorithme rassemble à lui seul 95 mots autour des résultats d'entreprise et des marchés.

Des trois liens entre thèmes les plus forts, deux se lisent sans difficulté : **Élections** ↔ **Personnalités**, les campagnes s'incarnant dans les hommes politiques, et **Résultats** ↔ **Marchés**, les publications d'entreprises nourrissant le même jour la chronique boursière. Le troisième, **Covid** ↔ **Énergie**, est d'une autre nature : « covid » et « transition » ne partagent pas un sujet, mais une **époque** — ce sont deux marqueurs des années 2020. C'est le premier signe d'un effet qui domine la suite du document.

Trois réserves : seuls 55 des 600 mots sont représentés, les liens montrés sont les plus forts et non les seuls, et une corrélation ne dit rien de la causalité.

Combien de thèmes sont statistiquement solides ?

Même 600 mots sans aucun lien réel afficheraient, sur un nombre fini de jours, des corrélations non nulles. La loi de Marchenko-Pastur donne la frontière de ce bruit : au-delà, une structure commune est défendable ; en-deçà, le hasard suffit.





Figure 2. – Les 600 valeurs propres de la matrice de corrélation, en échelle logarithmique (sans quoi les valeurs de droite, peu nombreuses, seraient invisibles face au bulk). La courbe noire est la densité de pur bruit prédite par Marchenko-Pastur : elle épouse le bulk observé. À droite du seuil, des valeurs qu'aucun hasard d'échantillonnage ne peut produire.

La courbe théorique épouse le bulk : ces 555 valeurs propres sont indiscernables du hasard. 45 en sortent, au-delà de 1,64 — un décompte de directions distinctes du bruit, pas de thèmes nommables.


Que contiennent les directions retenues ?

Chaque direction retenue est décrite par le poids qu'elle donne à chacun des 600 mots. Ces poids sont positifs ou négatifs : une direction **oppose** deux registres de vocabulaire, les jours où le premier domine étant les jours où le second est absent.


1. Chronique financière / années 2020




2. Budget et euro / art de vivre




3. Management / conjoncture dégradée



4. Entreprises / campagne électorale



5. Crise sanitaire / consommation



6. Territoires / actualité américaine




Figure 3. – Les six premières directions retenues, avec les mots qui les portent le plus. À droite les mots de poids positif, à gauche ceux de poids négatif. Ce sont des axes d'actualité concurrente. « plate » et « start » sont les têtes de « plate-forme » et « start-up », coupées par la tokenisation.

La direction la plus puissante n'oppose pas deux sujets mais deux **époques** : le vocabulaire de la chronique financière classique (« groupe », « chiffre », « marché ») face à celui des années 2020 (« emmanuel », « transition », « start », « trump », « covid », « numérique »). Sur vingt-cinq ans, la première ligne de partage du journal est chronologique.

Les suivantes sont thématiques, et découpent le journal en rubriques qui se disputent la place : le budget et la zone euro contre les pages art de vivre, le vocabulaire du management contre celui de la conjoncture, l'actualité des entreprises contre la campagne électorale, la crise sanitaire contre les prix à la consommation, les territoires contre les États-Unis. C'est exactement ce qu'il faudra surveiller après un rachat : un axe qui se déforme signale un déplacement de la couverture, pas seulement l'apparition d'un mot nouveau.

Nettoyer la matrice

Les 555 valeurs propres du bulk ne portent aucune information fiable. On les remplace par leur moyenne, en gardant intactes les 45 autres, puis on reconstruit la matrice.




Figure 4. – Chaque point est une paire de mots : sa corrélation avant nettoyage (horizontale) et après (verticale). La diagonale marque l’absence de changement. Les liens forts, à droite, sont ramenés vers le bas — c’est là que le bruit d’échantillonnage gonflait le plus les valeurs.

Le nuage reste serré autour de la diagonale : le nettoyage ne bouleverse pas la matrice. Les liens faibles ne bougent quasiment pas, les plus forts sont tirés vers le bas — une corrélation forte mesurée sur un échantillon fini est presque toujours un peu surestimée.

Le nombre de groupes bouge peu (24 contre 22), mais ce chiffre stable masque une recomposition réelle : 2,8 % des paires de mots changent de statut. Le débruitage ne change pas le nombre de boîtes, il change leur contenu. Et le résultat ne dépend pas de la valeur exacte du seuil : en gardant 30 valeurs propres au lieu de 45, on trouve 23 groupes ; avec 60, 22 ; contre 24 au seuil exact.

Cela comptera pour la suite : découpé en fenêtres avant/après rachat, chaque période comptera un millier de jours au lieu de 7 618 : le ratio mots/jours montera bien au-dessus de 0,079 et les matrices seront beaucoup plus bruitées qu’ici.