

Des articles aux sauts lexicaux : chaîne de traitement et modèle zéro

Le Monde, 1944-2025 — phase 3 du mémoire

Corto

Objectif

Question de recherche du mémoire : *les rachats de journaux français modifient-ils la couverture thématique ?*
Avant de comparer des journaux et des dates de rachat, il faut un instrument capable de repérer et de décrire **tous** les moments où un mot « saute » dans un journal.

La phase 3 construit cet instrument sur Le Monde (26 917 jours de parution, décembre 1944 à 2025) : détecter les sauts de chaque mot, en faire des *datapoints* comparables, puis chercher à l'aveugle — sans savoir quel mot ni quelle date — quelles **formes** de sauts existent. C'est le « modèle zéro » : les mots ne sont que des courbes, et on laisse les données parler avant d'y remettre du sens.

La chaîne

#	Étape	Script	Sortie	Volume
1	Choisir le vocabulaire	<code>scan_vocab.py</code>	top-10 000 mots	441 081 mots scannés
2	Extraire les séries	<code>masse.py</code>	matrice jours × mots	26 917 × 10 000
3	Détecter les pics	<code>pics_masse.py</code>	liste (mot, jour, p-valueur)	164 254 pics
4	Dédoublonner (NMS)	<code>nms.py</code>	un représentant par événement	123 465 gardés
5	Découper les fenêtres	<code>fenetres_masse.py</code>	matrice des fenêtres ±15 j	123 310 × 31
6	PCA	<code>pca.py</code>	composantes, projections	31 × 31

Chaque étape lit la sortie de la précédente (scripts dans [rupture/](#)) ; tout tourne sur le serveur en quelques secondes à quelques minutes. Les choix de vocabulaire — unité = la graphie, top-10 000 par nombre de jours actifs, fusion des doublons OCR — sont détaillés dans le journal des 21-22/07.

Étape 3 — détection des pics

Pour chaque mot, on compte ses occurrences jour par jour : X_t occurrences sur N_t mots publiés. On ajuste une loi décrivant le comportement *habituel* du mot — un mélange : probabilité p_0 de ne pas apparaître, sinon une binomiale négative proportionnelle à N_t . Un jour est déclaré **pic** quand le comptage observé serait quasi impossible sous cette loi : $p_t < 10^{-4}$. On appelle **surprise** la quantité $-\log_{10}(p_t)$; surprise 4 = seuil de détection, surprise 40 = jour astronomiquement anormal.




Figure 1. – Le mot « internet » : la série $f_t = X_t/N_t$ (haut), l’histogramme des comptages avec la loi ajustée (bas gauche), les p-valeurs (bas droite). Points rouges : pics détectés — l’irruption du mot entre 1995 et 2001.

Sur les 10 000 mots : **164 254 pics**, 9 817 mots avec au moins un pic, 11 mots dont l’ajustement échoue et qui sont consignés.

Étape 4 — un événement, un datapoint

Un événement qui dure produit des dizaines de jours-pics d’affilée ; sans traitement, il entrerait des dizaines de fois dans l’analyse. L’idée naïve — fusionner de proche en proche les pics rapprochés, garder le meilleur de chaque paquet — souffre du **chaînage** : un pont de pics espacés de moins de 31 jours soude des *années* en un seul bloc. Sur nos données, 164 groupes géants de ce type ; « syrienne » aurait fondu 760 jours de parution (2012-2014) en un point unique.

La solution retenue est la *non-maximal suppression* gloutonne, héritée de la détection d’objets en vision par ordinateur : trier les pics du mot par surprise décroissante, garder le plus surprenant, supprimer ses voisins à moins de 31 jours de parution **de lui**, recommencer. Un pic supprimé ne supprime personne : la suppression ne se propage pas, donc pas de groupe géant. Et 31 jours étant la largeur d’une fenêtre, deux représentants gardés n’ont jamais de fenêtres qui se chevauchent.

« syrienne », 2011-2014 : le chaînage fusionnait ces pics en un seul groupe (un seul datapoint) ; le NMS glouton garde un représentant par sous-événement




Figure 2. – « syrienne » 2011-2014 : 220 pics détectés (bleu), 24 représentants gardés (cercles rouges) — un par sous-événement de la guerre civile, là où le chaînage n’en gardait qu’un seul. Le NMS garde le jour le plus *surprenant*, pas le plus haut en fréquence.

Contre-vérification indépendante par `scipy.signal.find_peaks` : résultat identique sur 9 771 mots sur 9 817, les écarts restants étant des égalités de surprise départagées différemment. Bilan : **123 465 représentants**, un pic détecté sur quatre était un doublon de fenêtre.

Étape 5 — mise à l'échelle des fenêtres

Autour de chaque représentant, on découpe la fenêtre des fréquences f_t sur ± 15 jours de parution : une courbe de 31 points, un datapoint. On ne peut pas comparer directement la fenêtre de « guerre » et celle de « francisco » : l'analyse ne verrait que « certains mots sont plus fréquents que d'autres ». Chaque fenêtre est donc **normalisée sur elle-même** en z-score — on soustrait sa moyenne, on divise par son écart-type, il ne reste que la forme.

C'était l'objet d'une mise en garde de Benoît : l'option de normalisation intégrée des fonctions de PCA standardise *colonne par colonne*, ce qui ne supprime pas les écarts de niveau entre fenêtres. Vérification faite, avec cette option la première composante capte 63,5 % de la variance et sa projection est corrélée à 0,99 au niveau moyen brut de la fenêtre : elle mesure « le mot est-il fréquent », pas la forme du saut. Cette variante est conservée comme témoin négatif.




Figure 3. — Variance expliquée par composante pour les trois normalisations. Le témoin « colonne par colonne » (orange) écrase tout sur une première composante artefactuelle ; le z-score par fenêtre (bleu) étale la variance sur des formes réelles.

Étape 6 — quelles formes de sauts existent ?

La PCA cherche les profils temporels qui expliquent le mieux les différences entre les 123 310 fenêtres. Deux constats.

Le spectre est plat : 9,2 %, 6,2 %, 5,3 %, 4,6 %, 4,2 %, 3,8 % — les six premières composantes ne portent qu'un tiers de la variance, et il en faut quinze pour atteindre 62 %. Le repère qui donne sa force à ce constat : la 31e valeur propre étant nulle par construction (une fenêtre z-scorée a une somme nulle), le nuage vit dans 30 dimensions ; un nuage **sans aucune structure** donnerait donc 3,33 % par composante. Seules les neuf premières passent au-dessus de cette ligne, pour un excédent total d'environ 14 points. Il n'existe pas deux ou trois formes archétypales qui résumeraient les sauts : la diversité des fenêtres est réelle, et c'est le premier résultat du modèle zéro.

Les premières formes sont simples et lisibles. Lues sur les composantes elles-mêmes : la composante 1 oppose le jour du pic (+0,55) à ses deux voisins immédiats (−0,46 et −0,49) — *le pic tient-il sur un seul jour, ou déborde-t-il ?* La composante 2 est négative avant le pic (−0,58 la veille) et positive durablement après (+0,41, puis ~+0,10 jusqu'à J+15) — *le sujet s'installe-t-il ?* La composante 3 fait l'inverse — *le sujet se clôt-il ?*




Figure 4. – Les six premières composantes comme profils temporels (bleu : z-score ; vert : variante [0,1]). 1 : pic isolé d'un jour. 2 : niveau durablement plus élevé après le pic. 3 : bascule avant/après. 4 : creux la veille, rebond. 5-6 : oscillations lentes.

Dans le plan des deux premières composantes, les événements historiques se placent là où on les attend : les épisodes longs et soutenus du côté « activité durable », la masse des petits pics isolés de l'autre.




Figure 5. – Les 123 310 fenêtres dans le plan des composantes 1-2 (densité en bleu, échelle log). Points rouges : la fenêtre la plus surprenante de quelques mots-événements.

Les fenêtres réelles les plus alignées sur chaque composante confirment la lecture, et datent des jours qu'on reconnaît.

Fenêtres archétypes : les 3 sauts réels les plus alignés sur chaque composante (fenêtres en z-score)



Figure 6. – Pour chaque composante, les trois sauts réels les plus alignés. Composante 1 : pics d'un jour. Composante 2 : l'état de siège en Pologne (déc. 1981), les JO d'Athènes, le coup d'État de Pinochet (sept. 1973). Composante 3 : fin des JO de Paris, premier tour de la présidentielle 2022.

Reconstruction de la fenêtre « jaunes » du 08/12/2018 (gilets jaunes, en gris) par les premières composantes (bleu)




Figure 7. – La fenêtre « jaunes » du 08/12/2018 (acte IV des gilets jaunes) en gris, et sa reconstruction en bleu avec 1, 3, 6 et 15 composantes : 48 %, 52 %, 62 %, 89 % de la forme restituée.

Deux contrôles qui ont appris quelque chose

L'hypothèse « rythme hebdomadaire » est fausse. Les composantes 5-6 ressemblaient à une paire d'oscillations calées sur la semaine. Testé : la phase de ces oscillations n'a aucun lien avec le jour de la semaine

du pic (vecteurs moyens par jour de norme 0,01-0,14, contre une dispersion de 0,80 ; idem en se restreignant à 2000-2025). Ce sont des modes oscillants génériques.

La composante 4 a débusqué un artefact de données. Ses projections extrêmes viennent de fenêtres contenant un jour à corpus quasi vide — 177 mots publiés un jour de 1994, contre 57 000 en médiane : ce jour-là, deux occurrences suffisent à faire exploser $f_t = X_t/N_t$. 17 % des fenêtres contiennent un jour à $N_t < 5\,000$, et la part de projections extrêmes y est jusqu’à 18 fois plus élevée que dans les fenêtres saines.




Figure 8. – Part de fenêtres à projection extrême sur la composante 4 (au-delà de 2,5), selon le jour le plus creux de la fenêtre : l’enrichissement se concentre dans les fenêtres contenant un jour presque sans texte.

La V2 : corriger l’artefact sans déformer le résultat

Ce second contrôle a débouché le jour même sur une V2 de l’analyse (`rupture/pca.py`, désormais le défaut ; la V1 reste reproductible). Deux gestes, volontairement minimaux : dans chaque fenêtre, les jours à $N_t < 5\,000$ sont remplacés par l’interpolation linéaire des jours sains voisins (38 532 jours corrigés dans 19 554 fenêtres) ; les 1 505 fenêtres (1,2 %) dont le **jour central** est lui-même quasi vide sont écartées — le pic reste statistiquement valide, la détection tenant compte de N_t , mais la forme de sa fenêtre n’est pas exploitable.

Le seuil de 5 000 est posé à la frontière naturelle de la population pathologique (321 jours < 5 000 sur 26 917, puis la pente reprend), et le résultat n’y est pas sensible : entre 2 000 et 10 000, les premières composantes bougent de moins de 4 degrés.

Critère	V1	V2
Enrichissement corpus-vide de la comp. 4	×17,8	×0,5 (disparu)
Spectre (6 premières, %)	9,1 / 5,9 / 5,0 / 4,8 / 4,2 / 3,7	9,2 / 6,2 / 5,3 / 4,6 / 4,2 / 3,8
Stabilité des composantes (cos V1-V2)	—	≥ 0,94 sur les six premières
Archétypes de la comp. 4	jours à 177 mots (artefact)	« désastre », 19/03/2011 (Fukushima)

Seule la direction qui portait l’artefact se réorganise — 18,7° d’angle, contre moins de 3° pour les autres ; le spectre et les profils restent en place. Les conclusions du modèle zéro sont donc robustes au nettoyage, ce qui les consolide.




Figure 9. – Les six premières composantes après nettoyage V2 : quasi identiques à la V1 — la structure ne tenait pas à l’artefact.

Changer d’échelle : blocs de 3 jours, puis d’une semaine

La chaîne entière a été rejouée sur des timelines agrégées ([rupture/agreger.py](#)) : les jours de parution regroupés par 3, puis par 7, consécutifs et non chevauchants — X et N sommés par bloc, date du bloc = jour du milieu, même vocabulaire de 10 000 mots. Aucun autre réglage ne change : les scripts aval tournent tels quels, et les fenêtres couvrent ± 15 blocs, soit ± 45 puis ± 105 jours de parution.

Étape	journalier	3 jours	7 jours
Grille	26 917 jours	8 972 blocs	3 845 blocs
Pics détectés	164 254	76 267	44 955
Gardés après NMS	123 465	49 983	26 784
Fenêtres	123 310	49 771	26 457
Mots avec au moins un pic	9 817	8 514	7 028

L’artefact corpus-vide disparaît par construction. Le plus petit bloc de 3 jours pèse 17 785 mots, le plus petit bloc de 7 jours 55 684 — contre un seuil journalier de 5 000 : chaque jour pathologique est noyé dans un bloc avec des voisins sains. Une seule version est donc livrée pour ces grilles, tout seuil de nettoyage y donnant un résultat identique bit à bit. L’agrégation est une troisième réponse au problème, à côté de l’interpolation (V2) et des résidus standardisés (piste V3).

Les formes sont les mêmes aux trois échelles. Les composantes 1-2-3 de la grille 3 jours retrouvent leurs homologues journalières à 0,98, 0,92 et 0,90 de cosinus, la 4 à 0,85 ; en hebdomadaire, 0,97, 0,96, 0,98 et 0,80. Seules les composantes 5 et 6 échangent leur rang, à l’identique sur les deux grilles agrégées. Le pic isolé, l’installation durable, la bascule avant/après existent à l’échelle du jour comme à celle de la semaine : ces formes ne sont pas un artefact de l’échantillonnage journalier.

Le spectre reste plat. 11,5 / 8,0 / 5,6 / 4,8 / 4,3 / 3,8 % en 3 jours, 11,9 / 9,1 / 6,4 / 5,3 / 4,7 / 3,8 % en hebdomadaire. Plus la timeline est grossière, plus la variance se concentre — 33,3 %, 37,9 %, 41,2 % à $K = 6$ — mais la concentration reste modeste : toujours 8 composantes au-dessus de l’isotropie à 3,33 %, pas de typologie des sauts à ces échelles non plus. Les contrôles passent (corrélations de la projection 1 au niveau

moyen brut : 0,28 en 3 jours, 0,23 en hebdomadaire ; le témoin « colonne par colonne » monte, lui, à 75,9 % et 81,5 % de variance sur sa première composante).

PCA des fenêtres de sauts (lemonde3j) — profils temporels des premières composantes




Figure 10. – Les six premières composantes sur la grille 3 jours : les quatre premières sont celles de la grille journalière (cosinus $\geq 0,85$), les 5-6 échangent leur rang. L'axe horizontal est en blocs de 3 jours de parution.

Fenêtres archétypes, grille 3 jours : les 3 sauts réels les plus alignés sur chaque composante (fenêtres en z-score)



Figure 11. – Fenêtres archétypes de la grille 3 jours (le signe de chaque composante est aligné sur son homologue journalière). Composante 2 : le même bloc, celui du 12 septembre 2001, revient avec trois mots différents. Composante 3 : mai 2020, février 1991, novembre 1956 — trois épisodes qui retombent après le pic. Composante 4 : plus aucune fenêtre à corpus quasi vide.




Figure 12. – Les six premières composantes sur la grille hebdomadaire : les trois premières sont celles du journalier à cosinus $\geq 0,96$.

Fenêtres archétypes, grille 7 jours : les 3 sauts réels les plus alignés sur chaque composante (fenêtres en z-score)




Figure 13. – Fenêtres archétypes de la grille hebdomadaire. Composante 2 : le bloc du 14 septembre 2001, puis celui du 13 octobre 2023 (Gaza). Composante 4 : les trois fenêtres les plus alignées sont toutes du printemps 2020 — l’oscillation lente s’installe sur le plateau du confinement.

Deux réserves. Moitié moins de datapoints en 3 jours (49 771 : les sous-événements distants de moins de 93 jours de parution fusionnent sous le NMS), et la phase du découpage — quel jour ouvre le premier bloc — est arbitraire ; un contrôle en décalant le découpage de 1 et 2 jours reste à faire. Surtout, l’agrégation agit comme un **filtre passe-bas sur la détection elle-même** : un pic d’un seul jour se dilue dans un bloc dont le N est sept fois plus gros et peut passer sous le seuil — 2 800 mots qui avaient des pics en journalier n’en ont plus en hebdomadaire. Les trois grilles ne voient pas exactement la même population d’événements ; c’est un choix d’instrument, pas un défaut.

Limites connues et suite

Deux points notés pour plus tard : écrire la surprise en pleine précision dans les CSV — elle est arrondie à 2 décimales, ce qui explique 45 des 46 écarts de la contre-vérification du NMS ; et une piste de V3 discutée avec Benoît, remplir les fenêtres de **résidus standardisés** sous la loi ajustée plutôt que de fréquences brutes, ce qui éliminerait la sensibilité à N_t par construction.

La suite du travail : les statistiques du CSV des pics — livré ici pour les trois grilles — (co-sauts par jour, amplitudes, pics par mot) ; comparer avec la variante « vocabulaire $\geq 1\,000$ jours actifs » (39 316 mots) ; puis

l'objectif réel, refaire la chaîne sur les autres journaux et comparer les fenêtres *par journal* autour des mêmes pics — c'est là que la question des rachats se joue.